

활용 가이드라인

< 민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터 >

작성 담당기관	사업 총괄	나라지식정보
	데이터 수집	리스트
	데이터 정제	디그랩
	데이터 가공 및 검수	나라지식정보
	AI모델 개발	리스트
	나라지식정보	정규상
문서 버전	ver 1.0 ('24. 2. 10)	

'24년 초거대AI 확산 생태계 조성 활용 가이드라인(민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터) v1.0

문서 변경 이력

버전 (개정이력)	변경일자 (개정일자)	변경내용 (개정내용)	작성자	검토자	승인자
V.1.0	2024.02.10	최초 작성	박분선	정규상	정규상
			.		

목 차

데이터 개요 및 활용 요약.....

제1장 데이터 개요.....

1. 데이터 설명서
2. 메타데이터 구조표
3. 데이터 통계.....
4. 데이터 포맷.....
5. 데이터 구축 절차.....
6. 데이터 저장 구조 및 파일 명명 규칙

제2장 데이터 구축 및 활용.....

1. 데이터 구축
2. 학습모델
3. 서비스 활용

별첨 : 1. 데이터 구축 현황표(데이터 구축 현황, S3 데이터 파일 현황)

2. 개인정보 수집·이용 동의서

데이터 개요 및 활용 요약

<작성 시 주의사항>

- 데이터셋의 국문명, 영문명 모두 필수기재

- ‘데이터 개요 및 활용 요약’ 내용 작성 시, 데이터셋별로 기재

- ◆ 데이터셋의 특징을 전달하기 위함이므로 동일 과제에 여러 데이터셋이 존재할 경우 데이터셋별로 내용을 작성하여 제출 필요 (※ 동일 내용 반복 지양)

- ‘데이터 개요 및 활용 요약’ 내 이미지, 표, 그래프 등 첨부파일 별도 저장(필수)

- ◆ 요약 내용의 이미지와 표, 그래프 자료는 별도 저장 필수
- ◆ 위에서 언급한 이미지, 엑셀 파일 등을 아래의 포맷에 맞게 업로드
 - 요약 내용에 삽입된 이미지는 *.png 포맷(2배 크기)으로 저장
 - 요약 내용에 삽입된 표, 그래프 자료는 *.xls, *.xlsx 포맷으로 저장
 - 업로드 경로 : S3 Browser/2.최종산출물/4.교육자료/2.구축가이드

- ‘6. 구축 업체정보’ 작성 시, 아래의 요구사항 준수

- ◆ 프로젝트 참여 기업 정보는 누락 없이 모두 기재
 - 주관기관 책임자명/전화번호/메일주소 등은 연락 가능한 정보로 기재
- ◆ 데이터 이용자들에 대한 기술지원이 가능한 기관의 실무 담당자를 지정하여 기재
(최종 데이터 및 산출물에 대한 문의에 대응할 수 있는 담당자 정보)
- ◆ 전화번호는 회사 유선 번호 기재
 - 휴대폰 번호는 담당자의 개인정보이므로 본인확인 후 작성 필요(별첨2 참조)
- ◆ 담당자 이름, 연락처 등 정보 변경 시 AI허브에 데이터명과 함께 전달 필요
 - 전달 연락처 : aidata@aihub.kr

- 본 가이드라인은 한글파일(hwp, hwpX)로 제출

- ◆ 업로드 경로 : S3 Browser/2.최종산출물/4.교육자료/2.구축가이드

1. 공통항목

데이터명	국문	민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터						
	영문	Private Complaint LLM Pre-training and Instruction Tuning data						
데이터 구분		■ LLM		□ LMM		□ 합성데이터		
데이터 분야 ¹⁾		□ 법률	□ 보건의료	■ 행정사무	□ 교육			
		□ 미디어·콘텐츠	□ 제조·로보틱스	□ 교통·물류	□ 국방	□ 자유주제		
		□ 재난·안전·환경	□ 농림축수산	□ 글로벌 데이터	□ 온디바이스 AI			
데이터 유형 ²⁾		□ 이미지	□ 비디오	■ 텍스트	□ 오디오	□ 센서	□ 3D	□ 기타
데이터 개요	소개	1건당 500글자 이상, 최소 3턴 이상의 질의·답변으로 구성된 민간 민원 상담 텍스트 데이터 1만 건 이상(12,303건)을 수집하여 분류, 요약, 질의응답 유형의 Instruction Tuning Data 구축						
	구축 목적	민간 민원 상담 내용을 기반으로 LLM의 사전학습 및 Instruction Tuning을 위한 가공데이터를 구축하여 민원 상담 분야의 AI 서비스의 품질 제고 및 확산을 위함						
주요 키워드 ²⁾		□ 컴퓨터비전	□ 컴퓨터그래픽스	□ 농업	□ 축산업	□ 수산업		
		□ 자율주행	□ 교통,모빌리티	□ 안전	□ 환경	□ 제조		
		□ 로보틱스	□ 문화	□ 관광	□ 음성	■ 자연어		
		□ 헬스케어 의료		□ 헬스케어 건강서비스		□ 기타		
		// 기타 선택 시 키워드 기재(복수 기재 가능)						

1) 데이터 분야 하나만 선택 가능

2) 데이터 유형, 주요 키워드 복수 선택 가능

2. 메타데이터

데이터 형식	json
데이터 출처	하나카드, 엘지유플러스, 액티벤처
라벨링 유형	분류(자연어), 내용요약(자연어), 질의응답(자연어)
라벨링 형식	json
데이터 활용서비스	챗봇 서비스, AI 상담 도우미 서비스
데이터 구축년도	2024년
데이터 구축량	원천데이터 12,303건, 라벨링 데이터 132,401건
배포버전	ver 1.0

3. 세부데이터

데이터 설명 및 어노테이션 포맷 설명

1. 데이터 구성

Key	Description	Type	Child Type
source	원천대상	string	수집기관명
source_id	원천데이터 일련번호	string	000001
consulting_date	상담일시	string	20231005
consulting_category	수집기관별 업무 유형	string	유형명
client_gender	상담자 유형	string	남, 여
client_age	상담자 연령대	string	30대
consulting_time	상담시간	string	초
consulting_content	상담내용	string	
consulting_turns	대화턴 수	string	
consulting_length	상담 내용 길이	string	어절 수
tuning_type	분류, 요약, 질의응답	string	
instructions.instruction_id	지시문 아이디	number	1, 2, 3...
instructions.task	분류, 요약, 질의응답	string	
instructions.task_category	태스크 하위 카테고리	string	가공 유형명
instruction_length	지시문 길이(어절 수)	string	
input_length	input 데이터 길이(어절 수)	string	
output_length	output 데이터 길이(어절 수)	string	
instructions.instruction	지시문, 질문	string	
instructions.input	원천데이터 상담 내용 전체 또는 일부	string	
instructions.output	분류명, 요약문, 답변	string	

2. 어노테이션 포맷

No	항목명	타입	필수 구분	항목 설명	비고(예시)
1	source	string	필수	원천대상	하나카드
2	source_id	string	필수	원천데이터 일련번호	000001

'24년 초거대AI 확산 생태계 조성 활용 가이드라인(민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터) v1.0

3	consulting_date		string		상담일시	20231005
4	consulting_category		string		수집기관별 업무 유형	카드이용
5	client_gender		string		상담자 유형	남, 여
6	client_age		string		상담자 연령대	30대
7	consulting_time		string		상담시간	초
8	consulting_content		string	필수	상담내용	
9	consulting_turns		string	필수	대화턴 수	3턴 이상
1	consulting_length		string	필수	상담 내용 길이	125어절 이상 (rfp 500자 이상-1어절 평균 4자 추정)
1	instructions		array			
1	tuning_type		string	필수	분류, 요약, 질의 응답	
2	data		array			
	1	instructions.instruction_id	number	필수	지시문 아이디	"01"
	2	instructions.task	string	필수	분류, 요약, 질의 응답	
	3	instructions.task_category	string	필수	태스크 하위 카테 고리	분류 유형, 요약 유형, 질의응답 유형
	4	instruction_length	string	필수	지시문 길이(어절 수)	
	5	input_length	string	필수	input 데이터 길이 (어절 수)	
	6	output_length	string	필수	output 데이터 길 이(어절 수)	
	7	instructions.instruction	string	필수	지시문, 질문	
	8	instructions.input	string	필수	원천데이터 상담 내용 전체 또는 일부	
	9	instructions.output	string	필수	분류명, 요약문, 답변	

3. 데이터 포맷

'24년 초거대AI 확산 생태계 조성 활용 가이드라인(민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터) v1.0

민간 민원상담 데이터 작업

구문번호 : 44006 상담형식 : 선택약정 할인

접수가 완료된 건입니다.

상담사: 상담해 줄거슨 병화 LGU+<NAME>입니다.
고객: 네, 안녕하세요? 뭐 하나 여쭙게요.
상담사: 네, 안녕하세요?
고객: 제가 혹시 핸드폰 보정료에 있는 거 알만지 궁금해 가지구요.
상담사: 아 네, 공공하산들 통해 확인 바로 해 드리겠습니다.
고객: 네, 네.
상담사: 병화저장 <NAME> 고객님 본인 맞으십니까?
고객: 네.
상담사: 확인 감사합니다. 지금 본인인증보정으로 해볼 <CHARGE>해 요금 나오고 있으요, 보정 만가 날때 <DATE>입니다.
고객: <DATE>지요?
상담사: 네.
고객: <DATE>예요?
상담사: 네, 약정하실 해 <DATE>짜리거든요.
고객: 아 예, 알겠습니다.
상담사: 네, 더 궁금하신 건 있으십니까?
고객: 혹시 제가 선택약정 신청 가능할까요?
상담사: 잠깐 확인해 보겠습니다.
고객: 네.
상담사: 지금 가능하네요, 고객님.
고객: 그러면 제가 신청하고 그러면 할인받을 수 있는 거죠?
상담사: 네, 맞습니다.
고객: 아 그렇 오늘 해 주세요.
상담사: 아 네, 선택약정문 오늘부터 1년이나 2년으로 등록이 가능하시구요, 1년, 2년 기간은 다르지만 할인금액은 25%로 동일한데 몇 년으로 등록을 해 드리겠 될까요?
고객: 1년으로.
상담사: 알겠습니다. 등록을 위해서 제가 안내사항 잠깐 읽어드리도록 하겠습니다. 읽어보시고 내라고 말씀해 주세요.
고객: 네.
상담사: 지금부터 선택약정할인 혜택 가입 과정을 진행하겠습니다. 기존 유선집 무지까지 못하면 반환금이 나오는데 주요사항은 문자로 발송해 드렸습니다. 다 반환금이 발생하는 경우는 중도해지 이직을 단말기요 기기변경 약정미수계 약이변경에 해당합니다. 실질적인 내용은 홈페이지에서 확인 가능합니다. 선택약정할인 가입에 동의하십니까?
고객: 네.
상담사: 네, 감사합니다. 제가 약정 내용을 고객님께 문자로 보내드렸는데요, 전화 잠시 마시고 문자 한번 확인해 주시겠습니까?
고객: 네, 근데 <DATE>은 뭐예요?
상담사: 아 네, 예를 들어서 고객님께서 <DATE> 등록을 하셨잖아요.
고객: 네.

수정

상주해

구독 대상 선택
1건
분류
민원 상담 조건
Instruction: 지시문
의 민원 상담의 내용이 "단말 요금 민원"과 "다수 요금 민원" 중 어디에 해당해?
Input: 원문
원문 전체 입력 (입력값이 무시되고 작업저장시 원문 전체가 저장 됩니다.)
Output: 분류 종류
다수 요금 민원

구독 대상 선택
2건
분류
민원 상담 주제
Instruction: 지시문
고객이 상담한 내용은 "선물 및 서비스 일반", "주문/결제/입금 확인", "취소/반품/교환/환불/AS", "배송 문의", "제품 문의", "제품", "이벤트/할인", "포인트", "기타" 가운데 어디에 포함하나요?
Input: 원문
원문 전체 입력 (입력값이 무시되고 작업저장시 원문 전체가 저장 됩니다.)
Output: 분류 종류
이벤트/할인

```

1 [{"source": "하나카드",
2  "source_id": "20593",
3  "consulting_category": "도난/분실 신청/해제",
4  "client_gender": "여자",
5  "client_age": "50대",
6  "consulting_time": "",
7  "consulting_turns": "37",
8  "consulting_length": "166",
9  "consulting_content": "상담사: 상담원 ▲▲▲입니다.₩n손님: 네, 저 ▲▲카드 문의좀 드릴려고요.₩n상담사: 네.₩n상담사: 네, 고객님. 그럼 본인 확인",
10 "instructions": [{"instruction_id": 0,
11  "task": "분류",
12  "task_category": "상담 주제",
13  "instruction_length": "19",
14  "input_length": "166",
15  "output_length": "1",
16  "instruction": "상담 주제는 ₩"상품 및 서비스 일반₩", ₩"주문/결제/입금 확인₩", ₩"취소/반품/교환/환불/AS₩", ₩"배송 문의₩", ₩"회원 관리₩",
17  "input": "상담사: 상담원 ▲▲▲입니다.₩n손님: 네, 저 ▲▲카드 문의좀 드릴려고요.₩n상담사: 네.₩n상담사: 네, 고객님. 그럼 본인 확인 후 안내를",
18  "output": "취소/반품/교환/환불/AS"}],
19 }],
20 }],
21 }],
22 }],
23 }],
24 }],
25 }]
```

4. 실제 예시

4. 데이터 통계

데이터 구축 규모
및
데이터 분포

총 상담 데이터 건수	12,303건		
총 어절 수	총 3,580,857어절		
수집 출처	수집처	건수	비율
	하나카드	76,804	58.01%
	엘지유플러스	43,920	33.17%
	액티벤처	11,677	8.82%
	합계	132,401	100%
상담데이터 1건당 평균 Instruction tuning data 수	평균 10.76건 (가공데이터 132,401건 / 원천데이터 12,303건)		
평균 대화턴 수	평균 38.09턴		
평균 어절 수	어절 수 분포	건수	비율
	124 어절 이하	3	0.02%
	125~200 어절	1,819	14.79%
	201~250 어절	2,478	20.14%
	251~300 어절	2,478	20.14%
	301 어절 이상	5,525	44.91%
	합계	12,303	100%
수집기관별 업무 유형 분포	하나카드		
	업무 분야	건수	비율
	이용내역 안내	11,034	14.37%
	선결제/즉시출금	10,536	13.72%
	도난/분실 신청/해제	5,735	7.47%
	한도상향 접수/처리	4,728	6.16%
	결제대금 안내	3,837	5.00%
	승인취소/매출취소 안내	3,584	4.67%
	가상 계좌 안내/예약/취소	3,470	4.52%
	이벤트 안내	2,493	3.25%
	한도 안내	1,875	2.44%
	연체대금 즉시출금	,852	2.41%
	결제계좌 안내/변경	1,832	2.39%
	일부결제대금이월약정 해지	1,812	2.36%
	이용방법 안내	1,807	2.35%
	정부지원 바우처 (등유, 임신 등)	1,766	2.30%
	결제일 안내/변경/취소	1,678	2.18%
	그 외 40건 업무유형	18,765	24.43%

		합계		75,804	100%
		엘지유플러스			
		업무 분야		건수	비율
		요금 안내		8,428	19.19%
		요금 납부		6,360	14.48%
		요금제 변경		5,906	13.45%
		선택약정 할인		4,630	10.54%
		납부 방법 변경		3,944	8.98%
		부가서비스 안내		2,549	5.80%
		소액 결제		2,283	5.20%
		휴대폰 정지/분실/파손		1,958	4.46%
		기기변경		1,112	2.53%
		명의/번호/유심 해지		1,037	2.36%
		그외 50건 업무유형		5713	13.01%
		합계		43,920	100%
		엑티벤처			
		업무 분야		건수	비율
		상품예약 및 결제		6,350	54.38%
		요금 및 견적		4,808	41.17%
		일반문의(여행준비, 인터넷, 교통, 안전 등)		261	2.24%
		예약변경 및 취소		258	2.21%
		합계		11,677	100%
	분류 유형 분포	분류		건수	비율
		상담 주제		12,323	20.04%
		상담 요건		12,303	19.99%
		상담 내용		12,303	19.99%
		상담 사유		12,303	19.99%
		상담 결과		12,303	19.99%
		합계		61,535	100%
		세부 분류 유형 분포	상담 주제		건수
	상품 및 서비스 일반		3,540	28.73%	
	주문/결제/입금 확인		3,826	31.05%	
	취소/반품/교환/환불/AS		1,629	13.22%	
	회원 관리		1,684	13.67%	
	배송 문의		36	0.29%	
	이벤트/할인		849	6.89%	

		콘텐츠	14	0.11%
		제휴	619	5.02%
		기타	126	1.02%
		합계	12,323	100%
		상담 요건	건수	비율
		단일 요건 민원	10,249	83.30%
		다수 요건 민원	2,054	16.70%
		합계	12,303	100%
		상담 내용	건수	비율
		일반 문의 상담	6,083	49.44%
		업무 처리 상담	6,191	50.32%
		고충 상담	29	0.24%
		합계	12,303	100%
		상담 사유	건수	비율
		업체	425	3.45%
		민원인	11,878	96.55%
		합계	12,303	100%
		상담 결과	건수	비율
		만족	9,981	81.12%
		미흡	1,025	8.33%
		해결 불가	259	2.11%
		추가 상담 필요	1,038	8.44%
		합계	12,303	100%
	요약 유형 분포	요약 유형	건수	비율
		기본 요약	12,341	30.76%
		길이 제한 요약	10,527	26.24%
		주제 중점 요약	8,709	21.71%
		핵심 정보 추출 요약	8,538	21.29%
		합계	40,115	100%
	요약문 길이 분포	요약문 어절 수 분포	건수	비율
		5~20 어절	4,800	11.97%
		21~40 어절	25,672	64.00%


		41~60 어절	6,164	15.36%
		61 어절 이상	3,479	8.67%
		합계	40,115	100%
	질의 유형 분포	질의 유형	건수	비율
		의문사형	18,491	60.13%
		예/아니요형	12,260	39.87%
		합계	30,751	100%
	질의 답변 길이 분포	지시(질의)문	건수	비율
		1~3 어절	193	0.63%
		4~6 어절	11,595	37.71%
		7~13 어절	18,569	60.38%
		14 어절 이상	394	1.28%
		합계	30,751	100%
		답변문	건수	비율
		1~3 어절	17,456	56.77%
		4~6 어절	6,824	22.19%
		7~13 어절	6,108	19.86%
		14 어절 이상	363	1.18%
		합계	30,751	100%
	가공 유형 분포	가공 유형	건수	비율
		분류	61,535	46.47%
		요약	40,115	30.30%
		질의응답	30,751	23.23%
		합계	132,401	100%

5. 활용 AI모델 설명

활용 AI모델


• 분류 모델 : Meta-Llama-3-8B-Instruct

- * LLAMA3 모델은 메타의 AI 그룹이 개발한 차세대 사전 훈련된 대규모 언어 모델(LLM)
- * 128K 토큰의 vocabulary 적용
- * 사전학습과 강화 학습 과정의 개선을 통해 추론, 코드 생성 및 지시 수행 등의 능력이 기존 모델 대비 대폭 향상
- * Grouped Query Attention(GQA)을 통해 추론 효율성 개선
- * 파라미터 개수에 따라 다양한 모델 크기를 제공



• 요약 및 질의응답 모델 : openchat-3.5-0106(mistral)

- * OpenChat 모델은 C-RLFT 방법론을 사용해 파인튜닝한 오픈 소스 언어 모델
- * C-RLFT 방법론은 이미 라벨링된 다양한 품질(고품질과 저품질)의 데이터를 활용하여 클래스 조건화 데이터셋을 구축하고 표준 RLHF 방법론과 유사하게 보상을 최대화하는 방식으로 학습
- * OpenChat 최신 모델은 Mistral 과 Gemma을 기본 모델로 한 파인튜닝 모델을 제공
- * 최근에 OpenChat-3.5 의 업그레이드 버전이 출시되었으며 다양한 벤치마크에서 뛰어난 성능을 보임. 한국어의 성능도 우수함



6. 구축 업체정보

▶ 주관기관			
기관명	나라지식정보		
담당자명	정규상		
전화번호 (유선번호) ¹⁾	02-3141-7644		
이메일 ¹⁾	ksjung@narainformation.com		
담당업무	총괄책임자		
▶ 참여기관 ²⁾			
기관명1	디그랩		
담당업무1	정제		
기관명2	리스트		
담당업무2	수집, 모델링		
문의처 ³⁾	책임자	전화번호 (유선번호) ¹⁾	이메일 ¹⁾
	담당자		
데이터문의처	박분선	02-3141-7644	bspark27@hanmail.net
	김희영	02-3141-7644	ahjilu@dgraib.co.kr
AI모델 관련 문의처	강혁	02-2632-5133	sohohuk@li-st.com
	최두	02-2632-5133	codelua@li-st.com
저작도구 관련 문의처	강혁	02-2632-5133	sohohuk@li-st.com
	최두	02-2632-5133	codelua@li-st.com


1) 개인 휴대폰 번호 및 이메일 작성 시, 개인정보 보호법에 따라 '별첨 2. 개인정보 수집·이용 동의서' 작성

2) 참여기관 정보(기관명, 담당업무) 모두 기입

3) 사용자 문의의 대응이 가능해야 하며, 담당자 변경 시 반드시 AI 허브 운영팀(aidata@aihub.kr)으로 변경 사항 공유

제1장 데이터 개요

1. 데이터 설명서

데이터 셋명	국문	민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터
	영문	Private Complaint LLM Pre-training and Instruction Tuning data
구축 목적		민간 민원 상담 내용을 기반으로 LLM의 사전학습 및 Instruction Tuning을 위한 가공데이터를 구축하여 민원 상담 분야의 AI 서비스의 품질 제고 및 확산을 위함
소개		1건당 500글자 이상, 최소 3턴 이상의 질의·답변으로 구성된 민간 민원 상담 텍스트 데이터 1.2만 건 이상을 수집하여 분류, 요약, 질의응답 유형의 Instruction Tuning Data 13.2만 건 구축
활용 분야		AI 챗봇 서비스, AI 민원 상담 도우미 서비스
데이터 구축 절차 요약		민간 분야의 음성 민원 상담 데이터를 수집하여 텍스트화, 개인정보 처리 등의 정제, 가공도구를 활용한 분류, 요약, 질의응답의 Instruction Tuning  데이터 작성 작업을 진행하여 LLM 모델 학습을 진행

2. 메타데이터 구조표

데이터 분야	한국어	데이터 유형	텍스트
데이터 형식	json	데이터 출처	하나카드, 엘지유플러스, 액티벤처
라벨링 유형	분류, 요약, 질의응답	라벨링 형식	json
데이터 활용 서비스	AI 상담 챗봇 서비스 AI 민원 상담 도우미 서비스	데이터 구축년도/ 데이터 구축량	2024년/132,401건

2.1 메타데이터 어노테이션 포맷

No	속성명	타입	필수여부	속성 설명	예시
1	source	string	필수	원천대상	하나카드, 엘지유플러스, 액티벤처
2	source_id	string	필수	원천데이터 일련번호	000001
3	consulting_date	string		상담일시	20231005
4	consulting_category	string		수집기관별 업무 유형	카드이용
5	client_gender	string		상담자 유형	남, 여
6	client_age	string		상담자 연령대	30대
7	consulting_time	string		상담시간	초
8	consulting_content	string	필수	상담내용	
9	consulting_turns	string	필수	대화턴 수	3턴 이상
10	consulting_length	string	필수	상담 내용 길이	125어절 이상 (rfp 500자 이상-1어절 평균 4자 추정)

2.2 메타데이터 구성 예시

<하나카드 예

시>

```
[ {  
  "source" : "하나카드",  
  "source_id" : "200001",  
  "consulting_category" : "도난/분실 신청/해제",  
  "client_gender" : "여자",  
  "client_age" : "30대",  
  "consulting_time" : "",  
  "consulting_turns" : "40",  
  "consulting_length" : "202",  
  } ]  
}]
```

<엘지유플러스 예

시>

```
[ {  
  "source" : "엘지유플러스",  
  "source_id" : "42624",  
  "consulting_category" : "납부 방법 변경",  
  "consulting_time" : "",  
  "consulting_turns" : "30",  
  "consulting_length" : "245",  
  } ]  
}]
```

<엑티벤처 예

시>

```
[ {  
  "source" : "엑티벤처",  
  "source_id" : "90001",  
  "consulting_category" : "요금 및 견적",  
  "consulting_time" : "",  
  "consulting_turns" : "14",  
  "consulting_length" : "167",  
  } ]  
}]
```


3 데이터 통계

3.1 데이터 구축 규모

- 원시 데이터

파일포맷	데이터 규모	어절 단위 토큰 수량
wav, text	200,000건	58,000,000개

- 원천 데이터

파일포맷	데이터 규모	어절 단위 토큰 수량
json	12,303건	3,580,857개

- 라벨링 데이터

파일포맷	데이터 규모	어절 단위 토큰 수량
json	132,401건	3,082,944개

3.2 데이터 분포

○ 원천데이터 대비 가공(라벨링) 데이터 분포

원천 데이터					가공(라벨링) 데이터				
대분류	소분류	포맷	수량	단위	대분류	소분류	포맷	수량	단위
하나카드	-	json	7,283	건	하나카드	분류	json	36,435	건
						요약	json	21,557	건
						질의응답	json	18,812	건
엘지유플러스	-	json	4,020	건	엘지유플러스	분류	json	20,100	건
						요약	json	14,624	건
						질의응답	json	9,196	건
엑티벤처	-	json	1,000	건	엑티벤처	분류	json	5,000	건
						요약	json	3,934	건
						질의응답	json	2,743	건
합계			12,303	건	합계			132,401	건

○ 데이터 다양성 통계

- 원천데이터 수집 출처 분포

수집처	건수	비율
하나카드	76,804	58.01%
엘지유플러스	43,920	33.17%
엑티벤처	11,677	8.82%
합계	132,401	100%

- 원천데이터 업무 유형 분포

하나카드		
업무 분야	건수	비율
이용내역 안내	11,034	14.37%

'24년 초거대AI 확산 생태계 조성 활용 가이드라인(민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터) v1.0

선결제/즉시출금	10,536	13.72%
도난/분실 신청/해제	5,735	7.47%
한도상향 접수/처리	4,728	6.16%
결제대금 안내	3,837	5.00%
승인취소/매출취소 안내	3,584	4.67%
가상 계좌 안내/예약/취소	3,470	4.52%
이벤트 안내	2,493	3.25%
한도 안내	1,875	2.44%
연체대금 즉시출금	852	2.41%
결제계좌 안내/변경	1,832	2.39%
일부결제대금이월약정 해지	1,812	2.36%
이용방법 안내	1,807	2.35%
정부지원 바우처 (등유, 임신 등)	1,766	2.30%
결제일 안내/변경/취소	1,678	2.18%
그 외 40건 업무유형	18,765	24.43%
합계	75,804	100%
엘지유플러스		
업무 분야	건수	비율
요금 안내	8,428	19.19%
요금 납부	6,360	14.48%
요금제 변경	5,906	13.45%
선택약정 할인	4,630	10.54%
납부 방법 변경	3,944	8.98%
부가서비스 안내	2,549	5.80%
소액 결제	2,283	5.20%
휴대폰 정지/분실/파손	1,958	4.46%
기기변경	1,112	2.53%
명의/번호/유심 해지	1,037	2.36%
그외 50건 업무유형	5713	13.01%
합계	43,920	100%
엑티벤처		
업무 분야	건수	비율
상품예약 및 결제	6350	54.38%
요금 및 건적	4808	41.17%
일반문의(여행준비, 인터넷, 교통, 안전 등)	261	2.24%
예약변경 및 취소	258	2.21%
합계	11,677	100%

- 원천데이터 어절 수 분포

어절 수 분포	건수	비율
124 어절 이하	3	0.02%
125~200 어절	1,819	14.79%
201~250 어절	2,478	20.14%
251~300 어절	2,478	20.14%
301 어절 이상	5,525	44.91%
합계	12,303	100%

- 가공 유형 분포

가공 유형	건수	비율
분류	61,535	46.47%
요약	40,115	30.30%
질의응답	30,751	23.23%
합계	132,401	100%

- 가공데이터 분류 유형 분포

분류	건수	비율
상담 주제	12,323	20.04%
상담 요건	12,303	19.99%
상담 내용	12,303	19.99%
상담 사유	12,303	19.99%
상담 결과	12,303	19.99%
합계	61,535	100%

- 가공데이터 상세분류 유형 분포

'24년 초거대AI 확산 생태계 조성 활용 가이드라인(민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터) v1.0

상담 주제 분류	건수	비율
상품 및 서비스 일반	3,540	28.73%
주문/결제/입금 확인	3,826	31.05%
취소/반품/교환/환불/AS	1,629	13.22%
회원 관리	1,684	13.67%
배송 문의	36	0.29%
이벤트/할인	849	6.89%
콘텐츠	14	0.11%
제휴	619	5.02%
기타	126	1.02%
합계	12,323	100%

상담 요건 분류	건수	비율
단일 요건 민원	10,249	83.30%
다수 요건 민원	2,054	16.70%
합계	12,303	100%

상담 내용 분류	건수	비율
일반 문의 상담	6,083	49.44%
업무 처리 상담	6,191	50.32%
고충 상담	29	0.24%
합계	12,303	100%

상담 사유 분류	건수	비율
업체	425	3.45%
민원인	11,878	96.55%
합계	12,303	100%

상담 결과 분류	건수	비율
만족	4,496	44.16%

'24년 초거대AI 확산 생태계 조성 활용 가이드라인(민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터) v1.0

미흡	2,899	28.47%
해결 불가	2,266	22.25%
추가 상담 필요	521	5.12%
합계	10,182	100%

- 가공데이터 요약 유형 분포

요약 유형	건수	비율
기본 요약	12,341	30.76%
길이 제한 요약	10,527	26.24%
주제 중점 요약	8,709	21.71%
핵심 정보 추출 요약	8,538	21.29%
합계	40,115	100%

- 가공데이터 요약문 길이 분포

요약문 어절 수 분포	건수	비율
5~20 어절	4,800	11.97%
21~40 어절	25,672	64.00%
41~60 어절	6,164	15.36%
61 어절 이상	3,479	8.67%
합계	40,115	100%

- 가공데이터 질의 유형 분포

질의 유형	건수	비율
의문사형	18,491	60.13%
예/아니요형	12,260	39.87%
합계	30,751	100%

○ 디렉토리 구성 및 수량

데이터	분류 (1단계)	분류 (2단계)	분류 (3단계)	분류 (4단계)	라벨링 유형	포맷 (형식)	수량	파일비율	단위
민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터	1.Training	2.라벨링데 이터	하나카드	분류	분류	json	28,797	1:1	건
				요약	요약	json	17,103	1:1	건
				질의응답	질의응답	json	15,439	1:1	건
			엘지유플러 스	분류	분류	json	16,080	1:1	건
				요약	요약	json	11,690	1:1	건
				질의응답	질의응답	json	7,497	1:1	건
			엑티벤처	분류	분류	json	4,000	1:1	건
				요약	요약	json	3,164	1:1	건
				질의응답	질의응답	json	2,196	1:1	건
	2.Validation n	2.라벨링데 이터	하나카드	분류	분류	json	3,888	1:1	건
				요약	요약	json	2,112	1:1	건
				질의응답	질의응답	json	1,923	1:1	건
			엘지유플러 스	분류	분류	json	1,920	1:1	건
				요약	요약	json	1,406	1:1	건
				질의응답	질의응답	json	827	1:1	건
			엑티벤처	분류	분류	json	500	1:1	건
				요약	요약	json	373	1:1	건
				질의응답	질의응답	json	267	1:1	건
	3.Test	2.라벨링데 이터	하나카드	분류	분류	json	3,750	1:1	건
				요약	요약	json	2,342	1:1	건
				질의응답	질의응답	json	1,450	1:1	건
			엘지유플러 스	분류	분류	json	2,100	1:1	건
				요약	요약	json	1,528	1:1	건
				질의응답	질의응답	json	872	1:1	건
			엑티벤처	분류	분류	json	500	1:1	건
				요약	요약	json	397	1:1	건
				질의응답	질의응답	json	280	1:1	건
총수량							132,401	1:1	건

4. 데이터 포맷

○ 공정별 데이터 구성

구분	획득/수집 단계	정제 단계	가공 단계
데이터 구분	원시데이터	원천데이터	라벨링데이터
데이터 형태	디지털 파일	디지털 파일	디지털 파일
데이터 포맷	*.wav, .txt	*.json	*.json

○ 원천 데이터 : 라벨링 데이터 파일 관계

원천데이터 파일과 라벨링데이터 파일의 매칭관계를 표시하며, 1:1 / 1:多 / 多:1 외의 관계일 경우는 기타 설명에 명시

구분	원천 데이터 파일 : 라벨링 데이터 파일 매칭						
데이터 파일 관계	1:1		1: 多	○	多 : 1		기타
기타 설명							

○ 어노테이션 포맷

No	속성명	타입	필수여부	속성 설명	예시
1	source	string	필수	원천대상	하나카드
2	source_id	string	필수	원천데이터 일련번호	000001
3	consulting_date	string		상담일시	20231005
4	consulting_category	string		수집기관별 업무 유형	카드이용
5	client_gender	string		상담자 유형	남, 여
6	client_age	string		상담자 연령대	30대
7	consulting_time	string		상담시간	초
8	consulting_content	string	필수	상담내용	
9	consulting_turns	string	필수	대화턴 수	3턴 이상
10	consulting_length	string	필수	상담 내용 길이	125어절 이상 (rfp 500자 이상-1어절 평균 4자 추정)
11	instructions	array			
12	tuning_type	string	필수	분류, 요약, 질의응답	
13	data	array			
14	instructions.instruction_id	number	필수	지시문 아이디	"01"
15	instructions.task	string	필수	분류, 요약, 질의응답	
16	instructions.task_category	string	필수	태스크 하위 카테고리	분류 유형, 요약 유형, 질의응답 유형
17	instruction_length	string	필수	지시문 길이(어절 수)	
18	input_length	string	필수	input 데이터 길이(어절 수)	
19	output_length	string	필수	output 데이터 길이(어절 수)	
20	instructions.instruction	string	필수	지시문, 질문	
21	instructions.input	string	필수	원천데이터 상담 내용 전체 또는 일부	
22	instructions.output	string	필수	분류명, 요약문, 답변	

○ 어노테이션 예시

<분류 예시

```
>
[ {
  "source": "하나카드",
  "source_id": "200001",
  "consulting_category": "도난/분실 신청/해제",
  "client_gender": "여자",
  "client_age": "30대",
  "consulting_time": "",
  "consulting_turns": "40",
  "consulting_length": "202",
  "consulting_content": "상담사: 상담원 ▲▲▲입니다.Wn손님: 네, 안녕하세요? 제가 오늘 오전에 전화해가지고 네 ▲▲카드 뭐  
단기 요청을 드렸었는데Wn상담사: 네, 단기 요청 말씀 하시시는 걸까요? 네.Wn상담사: 네.Wn손님: 네, 지금 보니까 제가 예 한  
며칠 전에 쓴 게 오늘 결제가 된 거 같아서 그거 정보는 풀어 주셔도 될 것 같거든요.Wn상담사: 네.Wn상담사: 아 그러시군요.  
네 혹시 해당 카드 지금 소지하고 계신가요?Wn손님: 네.Wn손님: 아 그게 지금 어 잠시만요. 뭐 거기 적혀있는 정보가 필요한  
건가요?Wn상담사: 네.Wn상담사: 예, 저희 카드 인증이 필요하시기 때문이에요, 저희 이제Wn손님: 예.Wn상담사: 한번  
여쭙겠습니다, 네.Wn손님: 그쵸요?Wn손님: 아 네, 카드 가지고 있잖아요.Wn상담사: 아 네. 저희 어 명의자님 성함은 ▲▲▲ 님  
본인 맞으시고요?Wn손님: 네.Wn상담사: 예 찾으신 카드 재 정지 해제 원하시는 카드 끝에 번호 네 자리만 말씀  
부탁드리겠습니다.Wn손님: ▲▲▲▲▲▲Wn상담사: 아 네, 말씀 감사드립니다. 혹시 저희가 그 등록된Wn상담사: 어 핸드폰  
번호로 문자를 보내드리면 인증 번호 확인 가능하신가요?Wn손님: 어 어 한국 핸드폰 유심칩이 지금Wn손님: 어 쓰기가  
어렵거든요.Wn상담사: 아 알겠습니다, 우선 그러시면Wn손님: 아니면 카톡으로Wn상담사: 아 그러셨군요.Wn손님: 네.Wn상담사:  
네, 아니면 제가 다른 인증 방법을 한번 여쭙볼 텐데요, 그 연결돼 있는 저희 ▲▲은행 계좌 번호 혹시 말씀  
가능하실까요?Wn손님: 네.Wn손님: 아 네. Wn손님: 어 네. ▲▲▲Wn상담사: 네.Wn손님: ▲▲▲▲▲Wn상담사: 네Wn손님:  
▲▲▲▲▲Wn상담사: 아 네, 확인되었습니다. 저희가 일단은 바로 정지 해지해드려서요, 어 ▲▲ 신용카드 지금부터 바로  
이용 가능하십니다.Wn손님: 네.Wn손님: 아 네, 알겠습니다. 감사합니다.Wn상담사: 네, 감사합니다. 상담원  
▲▲▲이었습니다.Wn손님: 네.",
  "instructions": [ {
    "tuning_type": "분류",
    "data": [ {
      "instruction_id": 0,
      "task": "분류",
      "task_category": "상담 요건",
      "instruction_length": "11",
      "input_length": "202",
      "output_length": "3",
      "instruction": "상담 요건이 W"단일 요건 민원"과 W"다수 요건 민원" 중 어디에 속해?",
      "input": "상담사: 상담원 ▲▲▲입니다.Wn손님: 네, 안녕하세요? 제가 오늘 오전에 전화해가지고 네 ▲▲카드 뭐 단기 요청을  
드렸었는데Wn상담사: 네, 단기 요청 말씀 하시시는 걸까요? 네.Wn상담사: 네.Wn손님: 네, 지금 보니까 제가 예 한 며칠 전에 쓴  
게 오늘 결제가 된 거 같아서 그거 정보는 풀어 주셔도 될 것 같거든요.Wn상담사: 네.Wn상담사: 아 그러시군요. 네 혹시 해당  
카드 지금 소지하고 계신가요?Wn손님: 네.Wn손님: 아 그게 지금 어 잠시만요. 뭐 거기 적혀있는 정보가 필요한  
건가요?Wn상담사: 네.Wn상담사: 예, 저희 카드 인증이 필요하시기 때문이에요, 저희 이제Wn손님: 예.Wn상담사: 한번  
여쭙겠습니다, 네.Wn손님: 그쵸요?Wn손님: 아 네, 카드 가지고 있잖아요.Wn상담사: 아 네. 저희 어 명의자님 성함은 ▲▲▲ 님  
본인 맞으시고요?Wn손님: 네.Wn상담사: 예 찾으신 카드 재 정지 해제 원하시는 카드 끝에 번호 네 자리만 말씀  
부탁드리겠습니다.Wn손님: ▲▲▲▲▲Wn상담사: 아 네, 말씀 감사드립니다. 혹시 저희가 그 등록된Wn상담사: 어 핸드폰  
번호로 문자를 보내드리면 인증 번호 확인 가능하신가요?Wn손님: 어 어 한국 핸드폰 유심칩이 지금Wn손님: 어 쓰기가  
어렵거든요.Wn상담사: 아 알겠습니다, 우선 그러시면Wn손님: 아니면 카톡으로Wn상담사: 아 그러셨군요.Wn손님: 네.Wn상담사:  
네, 아니면 제가 다른 인증 방법을 한번 여쭙볼 텐데요, 그 연결돼 있는 저희 ▲▲은행 계좌 번호 혹시 말씀  
가능하실까요?Wn손님: 네.Wn손님: 아 네. Wn손님: 어 네. ▲▲▲Wn상담사: 네.Wn손님: ▲▲▲▲▲Wn상담사: 네Wn손님:  
▲▲▲▲▲Wn상담사: 아 네, 확인되었습니다. 저희가 일단은 바로 정지 해지해드려서요, 어 ▲▲ 신용카드 지금부터 바로  
이용 가능하십니다.Wn손님: 네.Wn손님: 아 네, 알겠습니다. 감사합니다.Wn상담사: 네, 감사합니다. 상담원  
▲▲▲이었습니다.Wn손님: 네.",
      "output": "단일 요건 민원"
    } ]
  } ]
}
```

<요약 예시

```
>
[ {
  "source": "하나카드",
  "source_id": "200001",
  "consulting_category": "도난/분실 신청/해제",
  "client_gender": "여자",
  "client_age": "30대",
  "consulting_time": "",
  "consulting_turns": "40",
  "consulting_length": "202",
  "consulting_content": "상담사: 상담원 ▲▲▲입니다.Wn손님: 네, 안녕하세요? 제가 오늘 오전에 전화해가지고 네 ▲▲카드 뭐  
단기 요청을 드렸었는데Wn상담사: 네, 단기 요청 말씀 하시시는 걸까요? 네.Wn상담사: 네.Wn손님: 네, 지금 보니까 제가 예 한  
며칠 전에 쓴 게 오늘 결제가 된 거 같아서 그거 정보는 풀어 주셔도 될 것 같거든요.Wn상담사: 네.Wn상담사: 아 그러시군요.  
네 혹시 해당 카드 지금 소지하고 계신가요?Wn손님: 네.Wn손님: 아 그게 지금 어 잠시만요. 뭐 거기 적혀있는 정보가 필요한  
건가요?Wn상담사: 네.Wn상담사: 예, 저희 카드 인증이 필요하시기 때문이에요, 저희 이제Wn손님: 예.Wn상담사: 한번  
여쭙겠습니다. 네.Wn손님: 그렇죠?Wn손님: 아 네, 카드 가지고 있잖아요.Wn상담사: 아 네. 저희 어 명의자님 성함은 ▲▲▲ 님  
본인 맞으시고요?Wn손님: 네.Wn상담사: 예 찾으신 카드 재 정지 해제 원하시는 카드 끝에 번호 네 자리만 말씀  
부탁드리겠습니다.Wn손님: ▲▲▲▲▲▲Wn상담사: 아 네, 말씀 감사드립니다. 혹시 저희가 그 등록된Wn상담사: 어 핸드폰  
번호로 문자를 보내드리면 인증 번호 확인 가능하신가요?Wn손님: 어 어 한국 핸드폰 유심칩이 지금Wn손님: 어 쓰기가  
어렵거든요.Wn상담사: 아 알겠습니다, 우선 그러시면Wn손님: 아니면 카톡으로Wn상담사: 아 그러셨군요.Wn손님: 네.Wn상담사:  
네, 아니면 제가 다른 인증 방법을 한번 여쭙볼 텐데요, 그 연결돼 있는 저희 ▲▲은행 계좌 번호 혹시 말씀  
가능하실까요?Wn손님: 네.Wn손님: 아 네. Wn손님: 어 네. ▲▲▲Wn상담사: 네.Wn손님: ▲▲▲▲▲Wn상담사: 네Wn손님:  
▲▲▲▲▲Wn상담사: 아 네, 확인되었습니다. 저희가 일단은 바로 정지 해지해드려서요. 어 ▲▲ 신용카드 지금부터 바로  
이용 가능하십니다.Wn손님: 네.Wn손님: 아 네, 알겠습니다. 감사합니다.Wn상담사: 네, 감사합니다. 상담원  
▲▲▲이었습니다.Wn손님: 네.",
  "instructions": [ {
    "tuning_type": "요약",
    "data": [ {
      "instruction_id": 3,
      "task": "요약",
      "task_category": "기본 요약",
      "instruction_length": "6",
      "input_length": "202",
      "output_length": "52",
      "instruction": "민원 내용과 답변 내용 전부를 요약하시오.",
      "input": "상담사: 상담원 ▲▲▲입니다.Wn손님: 네, 안녕하세요? 제가 오늘 오전에 전화해가지고 네 ▲▲카드 뭐 단기 요청을  
드렸었는데Wn상담사: 네, 단기 요청 말씀 하시시는 걸까요? 네.Wn상담사: 네.Wn손님: 네, 지금 보니까 제가 예 한 며칠 전에 쓴  
게 오늘 결제가 된 거 같아서 그거 정보는 풀어 주셔도 될 것 같거든요.Wn상담사: 네.Wn상담사: 아 그러시군요. 네 혹시 해당  
카드 지금 소지하고 계신가요?Wn손님: 네.Wn손님: 아 그게 지금 어 잠시만요. 뭐 거기 적혀있는 정보가 필요한  
건가요?Wn상담사: 네.Wn상담사: 예, 저희 카드 인증이 필요하시기 때문이에요, 저희 이제Wn손님: 예.Wn상담사: 한번  
여쭙겠습니다. 네.Wn손님: 그렇죠?Wn손님: 아 네, 카드 가지고 있잖아요.Wn상담사: 아 네. 저희 어 명의자님 성함은 ▲▲▲ 님  
본인 맞으시고요?Wn손님: 네.Wn상담사: 예 찾으신 카드 재 정지 해제 원하시는 카드 끝에 번호 네 자리만 말씀  
부탁드리겠습니다.Wn손님: ▲▲▲▲▲Wn상담사: 아 네, 말씀 감사드립니다. 혹시 저희가 그 등록된Wn상담사: 어 핸드폰  
번호로 문자를 보내드리면 인증 번호 확인 가능하신가요?Wn손님: 어 어 한국 핸드폰 유심칩이 지금Wn손님: 어 쓰기가  
어렵거든요.Wn상담사: 아 알겠습니다, 우선 그러시면Wn손님: 아니면 카톡으로Wn상담사: 아 그러셨군요.Wn손님: 네.Wn상담사:  
네, 아니면 제가 다른 인증 방법을 한번 여쭙볼 텐데요, 그 연결돼 있는 저희 ▲▲은행 계좌 번호 혹시 말씀  
가능하실까요?Wn손님: 네.Wn손님: 아 네. Wn손님: 어 네. ▲▲▲Wn상담사: 네.Wn손님: ▲▲▲▲▲Wn상담사: 네Wn손님:  
▲▲▲▲▲Wn상담사: 아 네, 확인되었습니다. 저희가 일단은 바로 정지 해지해드려서요. 어 ▲▲ 신용카드 지금부터 바로  
이용 가능하십니다.Wn손님: 네.Wn손님: 아 네, 알겠습니다. 감사합니다.Wn상담사: 네, 감사합니다. 상담원  
▲▲▲이었습니다.Wn손님: 네.",
      "output": "카드 정지 해제를 원하는 고객의 요청에 상담원은 카드 인증 후 가능하다고 답했다. 명의자의 이름을 물어 본인  
확인을 한 후, 정지 해제를 원하는 카드 끝 번호 네 자리를 확인하였고, 핸드폰 인증은 어렵다는 고객의 말에 카드에 연결되어  
있는 은행 계좌 번호 확인을 끝으로 정지 해제는 완료하였고 카드 사용은 바로 가능하다고 설명한 뒤 상담을 종료했다."
    } ]
  } ]
}
```

<질의응답 예


시>

'24년 초거대AI 확산 생태계 조성 활용 가이드라인(민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터) v1.0

```
[ {
  "source": "하나카드",
  "source_id": "200001",
  "consulting_category": "도난/분실 신청/해제",
  "client_gender": "여자",
  "client_age": "30대",
  "consulting_time": "",
  "consulting_turns": "40",
  "consulting_length": "202",
  "consulting_content": "상담사: 상담원 ▲▲▲입니다.Wn손님: 네, 안녕하세요? 제가 오늘 오전에 전화해가지고 네 ▲▲카드 뭐  
단기 요청을 드렸었는데Wn상담사: 네, 단기 요청 말씀 하시시는 걸까요? 네.Wn상담사: 네.Wn손님: 네, 지금 보니까 제가 예 한  
며칠 전에 쓴 게 오늘 결제가 된 거 같아서 그거 정보는 풀어 주셔도 될 것 같거든요.Wn상담사: 네.Wn상담사: 아 그러시군요.  
네 혹시 해당 카드 지금 소지하고 계신가요?Wn손님: 네.Wn손님: 아 그게 지금 어 잠시만요. 뭐 거기 적혀있는 정보가 필요한  
건가요?Wn상담사: 네.Wn상담사: 예, 저희 카드 인증이 필요하시기 때문이에요, 저희 이제Wn손님: 예.Wn상담사: 한번  
여쭙봤습니다, 네.Wn손님: 그렇죠?Wn손님: 아 네, 카드 가지고 있잖아요.Wn상담사: 아 네. 저희 어 명의자님 성함은 ▲▲▲ 님  
본인 맞으시고요?Wn손님: 네.Wn상담사: 예 찾으신 카드 재 정지 해제 원하시는 카드 끝에 번호 네 자리만 말씀  
부탁드리겠습니다.Wn손님: ▲▲▲▲▲▲Wn상담사: 아 네, 말씀 감사드립니다. 혹시 저희가 그 등록된Wn상담사: 어 핸드폰  
번호로 문자를 보내드리면 인증 번호 확인 가능하신가요?Wn손님: 어 어 한국 핸드폰 유심칩이 지금Wn손님: 어 쓰기가  
어렵거든요.Wn상담사: 아 알겠습니다, 우선 그러시면Wn손님: 아니면 카톡으로Wn상담사: 아 그러셨군요.Wn손님: 네.Wn상담사:  
네, 아니면 제가 다른 인증 방법을 한번 여쭙볼 텐데요, 그 연결돼 있는 저희 ▲▲은행 계좌 번호 혹시 말씀  
가능하실까요?Wn손님: 네.Wn손님: 아 네. Wn손님: 어 네. ▲▲▲▲Wn상담사: 네.Wn손님: ▲▲▲▲▲Wn상담사: 네Wn손님:  
▲▲▲▲▲Wn상담사: 아 네, 확인되었습니다. 저희가 일단은 바로 정지 해지해드려서요. 어 ▲▲ 신용카드 지금부터 바로  
이용 가능합니다.Wn손님: 네.Wn손님: 아 네, 알겠습니다. 감사합니다.Wn상담사: 네, 감사합니다. 상담원  
▲▲▲이었습니다.Wn손님: 네.",
  "instructions": [ {
    "tuning_type": "질의응답",
    "data": [ {
      "instruction_id": 7,
      "task": "질의응답",
      "task_category": "의문사형",
      "instruction_length": "8",
      "input_length": "202",
      "output_length": "7",
      "instruction": "고객은 왜 핸드폰 문자 인증을 하기 어렵다고 했니?",
      "input": "상담사: 상담원 ▲▲▲입니다.Wn손님: 네, 안녕하세요? 제가 오늘 오전에 전화해가지고 네 ▲▲카드 뭐 단기 요청을  
드렸었는데Wn상담사: 네, 단기 요청 말씀 하시시는 걸까요? 네.Wn상담사: 네.Wn손님: 네, 지금 보니까 제가 예 한 며칠 전에 쓴  
게 오늘 결제가 된 거 같아서 그거 정보는 풀어 주셔도 될 것 같거든요.Wn상담사: 네.Wn상담사: 아 그러시군요. 네 혹시 해당  
카드 지금 소지하고 계신가요?Wn손님: 네.Wn손님: 아 그게 지금 어 잠시만요. 뭐 거기 적혀있는 정보가 필요한  
건가요?Wn상담사: 네.Wn상담사: 예, 저희 카드 인증이 필요하시기 때문이에요, 저희 이제Wn손님: 예.Wn상담사: 한번  
여쭙봤습니다, 네.Wn손님: 그렇죠?Wn손님: 아 네, 카드 가지고 있잖아요.Wn상담사: 아 네. 저희 어 명의자님 성함은 ▲▲▲ 님  
본인 맞으시고요?Wn손님: 네.Wn상담사: 예 찾으신 카드 재 정지 해제 원하시는 카드 끝에 번호 네 자리만 말씀  
부탁드리겠습니다.Wn손님: ▲▲▲▲▲Wn상담사: 아 네, 말씀 감사드립니다. 혹시 저희가 그 등록된Wn상담사: 어 핸드폰  
번호로 문자를 보내드리면 인증 번호 확인 가능하신가요?Wn손님: 어 어 한국 핸드폰 유심칩이 지금Wn손님: 어 쓰기가  
어렵거든요.Wn상담사: 아 알겠습니다, 우선 그러시면Wn손님: 아니면 카톡으로Wn상담사: 아 그러셨군요.Wn손님: 네.Wn상담사:  
네, 아니면 제가 다른 인증 방법을 한번 여쭙볼 텐데요, 그 연결돼 있는 저희 ▲▲은행 계좌 번호 혹시 말씀  
가능하실까요?Wn손님: 네.Wn손님: 아 네. Wn손님: 어 네. ▲▲▲▲Wn상담사: 네.Wn손님: ▲▲▲▲▲Wn상담사: 네Wn손님:  
▲▲▲▲▲Wn상담사: 아 네, 확인되었습니다. 저희가 일단은 바로 정지 해지해드려서요. 어 ▲▲ 신용카드 지금부터 바로  
이용 가능합니다.Wn손님: 네.Wn손님: 아 네, 알겠습니다. 감사합니다.Wn상담사: 네, 감사합니다. 상담원  
▲▲▲이었습니다.Wn손님: 네.",
      "output": "지금은 한국 핸드폰 유심칩을 쓰기 어렵기 때문이야."
    } ]
  } ]
}
```

5. 데이터 구축 절차

5.1 데이터 구축 절차




○ 데이터 구축 절차

○ 공정별 데이터 구축 절차

1) 원시데이터 획득/수집

· 원시데이터 획득/수집 공정도



· 원시데이터 획득/수집 공정 상세 설명

작업단계	공정명	공정내용	산출물
------	-----	------	-----

작업단계	공정명	공정내용	산출물
수집 단계	수집 가이드라인 작성	• 분야별 획득 분량 계획 • 원시데이터 오디오(음원) 특성 정리 • 원시데이터 샘플 확인	수집 가이드라인
	획득/수집 교육	• 업무 지침 교육 • 데이터 특성 교육 • 데이터 수집 및 관리 체계 교육	
원시 데이터 획득	대상 데이터 분석	• 원시데이터 현황 정리 • 대상 데이터 후보 확보 • 대상 데이터 확정 및 수집	수집 데이터
	검수 및 선별	• 분량 확인 • 제외 대상 및 구성 요소 누락 여부 확인 • 합격 판정 • 원시데이터 생성 • 원시데이터 관리 폴더 이동 • 불합격 판정 • 제외 대상 데이터 폐기 • 작업 오류 케이스 작성	원시데이터 판정 결과보고서

2) 데이터 정제 작업 절차

절차	설명
음성 데이터 취합	• 수집 기관으로부터 원시 음성 데이터 인계
STT 파일로 변환	• 자사 보유 STT 엔진 활용하여 텍스트 변환(WER 기준 인식률 85 %)
전사 작업	• 음성데이터와 STT 텍스트 데이터를 비교하여 오인식 구간 검수 작업 진행

의미 없는 데이터 제거	• 단순 답변으로 구성된 데이터 제거
중복 데이터 제거	• STT 변환 후 중복 검사 tool을 활용하여 유사도 및 중복 검사 진행
부적절한 표현 삭제	• 상담원에 대한 부적절 표현 등에 대해 텍스트 삭제
개인정보 비식별화	• 개인정보에 해당하는 단어 치환작업으로 익명화 작업 진행
글자수 및 턴 수 확인	• 건당 500글자 미만으로 구성된 데이터 제거 • 3턴 미만의 질의/응답으로 구성된 데이터 제거
정제 작업 검사	• 원천데이터 적합성 여부 확인 • 정제 가이드라인 미준수 작업물 데이터 건수에서 제외
원천 데이터 취합	• 최종 정제 완료된 데이터는 FTP 서버에 업로드

3) 데이터 가공 작업 절차

항목	내용
전처리데이터(입력)	• 수집 및 정제 후 전처리된 원천데이터(문서 형태)를 라벨링 도구를 통해 제공
가이드라인 확인	• 라벨링 기준 및 검사 기준으로 활용되는 라벨링 가이드라인 확인
정제된 문서의 사전 정보 확인	• 수집 및 정제, 전처리 과정에서 생성된 문서 정보(카테고리, 글자 수 등)을 확인
메타 정보 확인	• 제목 등 메타 정보 확인
정제된 문서 정독	• 원천데이터 민원 상담 내용 확인
Instruction 입력	• 어떤 종류의 요약할 것인지 지시문 작성례를 참고하여 입력 • 분류와 요약 지시문은 1개 이상 필수 • 질의응답은 의문사형 또는 Y/N형으로 선택 작성하고 상담 내용이 적절치 않을 경우 다음 이동
분류 선택	• 필수 분류 외는 적정 분류값이 존재할 경우 작업

요약문 작성	• 주요 내용을 함축적으로 표현할 수 있는 단어들 선택(집단화, 추상화, 유의어) • 수정 불가 어군 및 수정 가능 어군을 선택 한 후, 수정 가능 어군을 수정 • 지시문에 맞는 분량으로 요약문 입력 • 반드시 1개 이상 작성
질의응답 작성	• 지시문에 맞게 작성

5.2 데이터 구축 기준

○ 획득/수집 기준

구분	수집 기준 및 고려 사항
데이터 다양성 확보	• 하나카드 최근 고객상담 데이터 30,000건, 엘지유플러스 160,000건, 액티벤처 10,000건 이상 확보 • 원천데이터는 최소 10,000건을 목표로 하고 있으며, 원시데이터는 200,000건을 획득/수집하여 데이터 부족 문제 해결 및 다양성 보장 • 분류별 구축 목표 수량을 사전 할당하여 분류별 수집 현황을 주기적으로 점검 • 기본 정제 작업량을 균등하게 배정하고, 상한선을 정하여 과적합을 방지함
데이터 편향 및 윤리 준수	• 혐오·차별·성적 발언·비속어(욕설) 등 인공지능의 윤리 문제와 관련하여 문제의 소지가 있는 내용은 가이드라인에 비윤리적 표현에 해당 사례를 명시적으로 제시하여 수집하지 않음 • 국가나 인종 차별, 혐오 소지가 있는 내용이 포함되었는지 확인하고 해당 사례가 발견될 경우 명시적으로 제시하며, 특히 주의함 • 특정 개인이나 단체 등을 비방하는 내용을 포함하는 대화도 혐오나 차별, 반사회적 발언 등이 나타날 문제가 있는 경우도 위와 같은 방식으로 처리함.

민감 정보 및 개인정보 보호	• 획득/수집 단계에서부터 민감정보 및 개인정보는 비식별해야 함을 데이터 수집처에 공유하고 획득/수집되는 원시데이터는 민감정보 및 개인정보에 대한 음성 비식별화된 데이터로 수령함 • 하나카드 및 엘지유플러스는 외부 반출 이전에 음성 비식별화를 처리하고, 이와 관련한 기술 지원을 요청할 경우 데이터 제공처에 방문하여 음성 비식별화를 지원함 • 다음 단계에서 대화 생성자가 인지하지 못하고서 개인정보를 언급할 가능성이 있으므로 기계적 정제 및 인적 정제단계를 통해 철저히 개인정보 비식별화 정제를 진행함 • 외부 반출 전 개인정보 비식별화하는 과정에서는, NIA ‘인공지능 학습용 데이터 품질관리 가이드라인 v3.1’ 별권 초거대 AI 데이터 구축 사례를 참고하여 개인정보를 정제하며, 추가로 필요한 대상과 항목에 대해서는 개인정보보호위원회의 가이드를 중용함 • 정제 작업 도구의 개인정보 검사 기능으로 1차 필터링한 후 해당 항목은 정제 작업자가 비식별화 유무를 판단하여 비식별화 대상인 경우 비식별화하거나 납품 제외함 • 비식별화된 데이터 항목은 지정된 형식에 따라 마스킹 처리되고, 라벨링 단계에서 자동 어노테이션을 통해 처리 • 기계적 정제 단계에서 검출되지 않는 개인정보 항목을 포함할 수 있으므로 작업자를 통한 인적 정제 방식으로 최종적으로 검출하고 정제함
사업수행계획서 및 데이터 구축요건 일치	• 사업수행계획서에 정의한 데이터 구축 기준에 맞추어 데이터를 획득/수집했는지 정기적으로 모니터링 및 검사하여 구축요건과 일치하게 함
데이터 획득/수집 시 품질 고려	• 인공지능 학습용 데이터 품질관리 가이드라인 3.1의 데이터 획득/수집 품질기준 및 개인정보 가이드라인 준수 등 정제에 필요한 사항을 반영하여 품질기준을 확보함
데이터 동기화	• 원시데이터를 기반으로 대화 데이터를 생성하므로 유니크한 ID로 관리함
학습모델 구축목적의 적합성	• 데이터 설계 담당자, 학습모델 개발자가 초기 수집한 원시데이터를 검토하고 모델 개발 목적에 부합하는지와 수집된 데이터의 제반 품질이 학습에 적합한지를 획득/수집의 초기에 검토하여 피드백하여 반영함

○ 정제 기준

기준	고려사항			
반복 멘트 삭제	• 단순 답변으로 구성된 데이터 삭제 ex) ‘안녕하세요’, ‘네’, ‘아니오’, ‘감사합니다’, ‘잠시만 기다려 주세요’			
글자 개수	• 문서 1건당 텍스트 500자 이상 여부 확인 미달 시 데이터 제외 처리			
대화 턴 수	• 상담사와 고객의 대화 민원 질의, 응답 내용 확인 3턴 미만 데이터 제외 처리			
민감정보 비식별화	개인 식별 정보	각종 번호	• 고유 식별번호(주민등록번호, 생년월일), 전화번호, 차량번호, 금융번호(계좌, 카드번호 등)	
		주소	• 거주지 및 직장 주소 등 구 이하 구체적 주소	
		성명	• 고객 성명(한글, 영문 등)	
		온라인	• 이메일, 아이디 등	
	내용 식별 정보	• 민원 해결을 위해 장소의 묘사, 상황정보 등으로 식별 가능한 정보가 등장하는 경우		
부적절한 표현	• 욕설 및 비속어 표현 • 차별 및 혐오 표현 • 부정적인 평가 표현			
데이터 적절성	• 민간 분야 카테고리 점검			

○ 가공(라벨링) 기준

형 태	항목명	어노테이션 방법
분류	Instruction	• 민원 상담 요건, 내용, 주제, 사유, 결과 분류 태스크를 설명하는 지시 문장을 작성
	분류	

요약		라벨링데이터 구분		세부 분류	
		분류	민원 상담 요건	단일 요건 민원	
				다수 요건 민원	
			민원 상담 내용	일반 문의 상담	
				업무 처리 상담	
				고충 상담	
			민원 상담 주제	상품 및 서비스	상품 및 서비스 일반
					주문/결제/입금 확인
					취소/반품/교환/환불/AS
					배송문의
				회원 관리	
				제휴	
				이벤트/할인	
				콘텐츠	
				기타	
			민원 상담 사유	업체	
				민원인	
			민원 상담 결과	만족	
				미흡	
				해결 불가	
추가 상담 필요					
Instruction instruction	• 4종의 요약 태스크를 설명하는 지시 문장을 작성				
요약문					

		지시문 유형	분류 기준	지시문 예시	
		기본 요약	요약 태스크가 명시적이거나 상세한 요구사항을 포함하지 않은 단순한 형태의 지시문	전체 민원 상담 내용을 요약해라.	
				이 민원 상담 건을 요약한 내용은?	
		길이 제한 요약	요약 태스크를 직접적으로 명시하고 요약문의 길이를 구체적으로 제한하는 지시문	주어진 지문을 읽고 그 내용을 1문장으로 요약하시오.	
				주어진 상담 내용을 3문장, 200자 이내로 요약해라.	
		주제 중점 요약	분류 주제를 포함하는 요약 지시문	상담의 결과가 어떻게 되었는지를 중심으로 요약문을 써주세요.	
민원인의 감정이 어떤지를 포함해서 요약해 주세요.					
핵심 정보 추출 요약	핵심 단어를 사용하거나 상담 내용의 핵심 단어 추출을 요구하는 지시문	예약 취소 요청에 대한 상담원의 답변이 무엇인지 짧게 서술하시오.			
		다음 대화의 핵심 단어가 든 문장을 포함해서 200자 내외의 글을 쓰세요.			
질의 응답	Instruction instruction	• 질의생성 태스크를 설명하는 지시 문장을 작성			
	질문답변	질의 유형	분류 기준	지시문 예시	
		의문사형	누가, 언제, 어디서, 무엇을, 어떻게, 왜 중 1가지를 선택하여 해당하는 질문	instruction	누구를 사용해서 질문을 만들어줘
				question	항만에 대한 공공교통시설개발사업의 타당성 평가서를 누구에게 제출하는거야
answer	해양수산부장관에게 제출해요				

			작성		
		Y/N 형	'예', '아니오' 답변이 나오도록 질문 작성	instruction	답변은 긍정으로 30자 이상 해줘
				question	대한민국 전체 물류의 움직임은 해운분야가 차지하는 비율이 나와 있어
				answer	네, 대한민국 전체 물류의 움직임은 수송량 기준으로 해서 국내 국제를 총망라해서 해운분야가 차지하는 게 63.4%라고 해요

5.3 라벨링 과정

○ 분류



- ① ‘분류’ 구축 대상 선택에서 분류 작업 선택. 분류 작업의 종류는 ‘민원 상담 요건’, ‘민원 상담 내용’, ‘민원 상담 주제’, ‘민원 상담 사유’, ‘민원 상담 결과’의 5가지 종류이며 원천데이터 1건에 대해 5가지 분류 작업을 모두 진행함
- ② Instruction(지시문) 작성. 지시문을 작성할 때에는 각 분류의 상세 분류를 포함하되 문장의 형식은 질의문, 명령문 등 다양하게 작성함

지시문 작성 예시

- [상담 주제] 다음 상담의 주제는 "상품 및 서비스 일반", "주문/결제/입금 확인", "취소/반품/교환/환불/AS", "배송 문의", "회원 관리", "제휴", "이벤트/할인", "콘텐츠", "기타" 중 무엇일까요?
- [상담 요건] 상담의 내용이 하나의 요건에 해당하는 "단일 요건 민원"인지, 여러 개의 요청이 들어있는 "다수 요건 민원"인지 알려 줘.
- [상담 내용] 다음 상담은 "일반 문의 상담", "업무 처리 상담", "고충 상담" 중에서 어디에 속하지?
- [상담 사유] 이 민원 상담이 발생한 원인은 "업체"에 있습니까? 아니면 "민원인"에게 있습니까?
- [상담 결과] 이 민원의 상담 결과는 "만족", "미흡", "해결 불가", "추가 상담 필요" 중 어디에 해당하니?

- ③ Input(원문) 입력. 좌측 원천데이터 전체를 대상으로 할 때에는 입력창 아래 '원문 전체 입력'에 체크하고, 원천데이터 부분을 대상으로 할 때에는 입력창에 해당 내용을 복사하여 넣음
- ④ Output(분류 종류) 선택. Input의 내용을 검토하여 적절한 분류를 선택함

분류 유형	세부 분류 유형	비고
상담 주제	상품 및 서비스 일반	모호함이 있거나 다중 주제를 포함하고 있을 때는 원천데이터 카테고리에 따라 분류
	주문/결제/입금 확인	
	취소/반품/교환/환불/AS	
	배송문의	
	회원 관리	
	제휴	
	이벤트/할인	
	콘텐츠	
	기타	
상담 요건	단일 요건 민원	1개의 주제를 가지고 여러 개의 사항에 대해 질문을 하는 것은 단일 요건으로 분류
	다수 요건 민원	
상담 내용	일반 문의 상담	상품 문의 등 일반적인 상담은 '일반 문의 상담', 예약과 취소 등 업무 처리에 관련된 상담은 '업무 처리 상담', 예약이 잘못되었거나 다른 물품을 배송하는 등 민원인이 피해를 보았다면 '고충 상담'
	업무 처리 상담	
	고충 상담	
상담 사유	업체	민원의 근본적인 시작점이 어디에 있는지를 기준으로 분류
	민원인	
상담 결과	만족	해결된 민원 상담(만족, 미흡), 미해결된 민원 상담(추가 상담 필요, 해결 불가)
	미흡	
	추가 상담 필요	
	해결 불가	

○ 요약



- ① 구축 대상 선택에서 '요약'선택 후 요약 작업의 유형 선택. 요약 작업의 종류는 '기본 요약', '길이 제한 요약', '주제 중점 요약', '핵심 정보 추출 요약'의 4가지 종류이며 원천데이터 1건에 대해 기본 요약은 '필수'로 진행하고 3가지 요약 작업에 대해서는 선택적으로 진행함
- ② Instruction(지시문) 작성. 지시문을 작성할 때에는 요약 작업의 종류에 맞게 작성 하되 문장의 형식은 질의문, 명령문 등 다양하게 작성함

지시문 작성 예시

- [기본 요약] 전체 민원 상담 내용을 요약하라.
- [기본 요약] 다음 상담 내용을 읽고 민원인의 질문과 답변을 요약해 줘.
- [길이 제한 요약] 다음 지문을 읽고 그 내용을 1문장으로 요약하십시오.
- [길이 제한 요약] 주어진 상담 내용을 2문장, 300자 이내로 줄여 줘.
- [주제 중점 요약] 교통 소외지역에 사는 민원인이 서부선 개통에 대해 질문한 4개의 궁금증을 간추려 줘.
- [주제 중점 요약] 예약 취소 요청에 대한 상담원의 답변이 무엇인지 짧게 서술하십시오.
- [핵심정보추출요약] 상담원의 답변을 핵심 단어를 포함해서 200자 내외로 쓰세요.
- [핵심정보추출요약] 희망두배 청년통장 사업이 어떤 사업인지 설명하세요.

- ③ Input(원문) 입력. 좌측 원천데이터 전체를 대상으로 할 때에는 입력창 아래 '원문 전체 입력'에 체크하고, 원천데이터 부분을 대상으로 할 때에는 입력창에 해당 내용을 복사하여 넣음
- ④ Output(요약문) 작성. Input의 내용을 검토하여 요약문을 작성함

요약문 작성 시 주의 사항

- 요약문의 형식, 내용, 분량 등은 지시문과 정확하게 일치해야 함
- 요약문은 서술식으로 작성하고, 서술어는 마침표로 작성
- 맞춤법, 문법, 문장부호 등의 오류가 없어야 함

○ 질의응답

- ① 구축 대상 선택에서 '질의응답'선택 후 질의응답 작업의 세부 유형 선택. 질의응답 작업의 종류는 '의문사형', '예/아니요형'의 2가지 종류이며 원천데이터 1건에 대해 선택적으로 작성함
- ② Instruction(지시문) 작성. 지시문의 유형을 선택함. 지시문의 유형은 의문사형 12종, 예/아니요형 4종으로 두 개 이상의 가공데이터를 만들 때에는 서로 다른 유형으로 작성하여야 함

질의문 유형	질문	답변	시스템 선택 유형	질의응답문 작성 시
의문사형	누가	단답형	누가-단답형	누구로 질문을 만들고 답변은 서술형이 아닌 형식으로 만든다.
		문장형	누가-문장형	누구로 질문을 만들고 답변은 문장으로 만든다.
	언제	단답형	언제-단답형	언제로 질문을 만들고 답변은 서술형이 아닌 형식으로 만든다.
		문장형	언제-문장형	언제로 질문을 만들고 답변은 문장으로 만든다.
	어디서	단답형	어디서-단답형	어디서로 질문을 만들고 답변은 서술형이 아닌 형식으로 만든다.
		문장형	어디서-문장형	어디서로 질문을 만들고 답변은 문장으로

	무엇을	단답형	무엇을-단답형	무엇으로 질문을 만들고 답변은 서술형이 아닌 형식으로 만든다.
		문장형	무엇을-문장형	무엇으로 질문을 만들고 답변은 문장으로 만든다.
	어떻게 (몇, 얼마)	단답형	어떻게(몇, 얼마)-단답형	어떻게(몇, 얼마)로 질문을 만들고 답변은 서술형이 아닌 형식으로 만든다.
		문장형	어떻게(몇, 얼마)-문장형	어떻게(몇, 얼마)로 질문을 만들고 답변은 문장으로 만든다.
	왜	단답형	왜-단답형	왜로 질문을 만들고 답변은 서술형이 아닌 형식으로 만든다.
		문장형	왜-문장형	왜로 질문을 만들고 답변은 문장으로 만든다.
	예/아 니요형	긍정형	단답형	긍정적인 답변이 나오는 서술형이 아닌 형식으로 만든다.
			문장형	긍정적인 문장형 답변이 나오는 질의응답문을 만든다.
		부정형	단답형	부정적인 답변이 나오는 서술형이 아닌 형식으로 만든다.
			문장형	부정적인 문장형 답변이 나오는 질의응답문을 만든다.

- ③ Input(원문) 입력. 좌측 원천데이터 전체를 대상으로 할 때에는 입력창 아래 ‘원문 전체 입력’에 체크하고, 원천데이터 부분을 대상으로 할 때에는 입력창에 해당 내용을 복사하여 넣음
- ④ Output(질문) 작성. Input의 내용을 검토하여 Instruction(지시문)에서 선택된 질의응답 세부유형에 맞게 질문을 작성함
- ⑤ Output(답변) 작성. Instruction(지시문)과 Output(질문)을 고려하여 적절한 답변을 작성함

질의문/답변 작성 예시

질의문/답변 작성 예시	
▣ 의문사형 • 누가-단답형; 현장에서 보호자와 아이를 동반하여 2인 1보드를 진행한 경우 누구의 판단하에 참가자의 동의를 받은 후 패들보드에 태웠어?/안전요원 • 언제-문장형; 민원인이 예약하려는 날짜는 언제야?/5월 25일이다. • 어디서-단답형; 단체 예약은 어디에서 할 수 있지?/콜센터나 현장 매표소 • 무엇을-문장형; 민원인은 무엇을 요구하고 있습니까?/한강시민공원 자전거길에 로드 자전거 출입을 금지해 달라고 요청하고 있습니다. • 어떻게(몇, 얼마)-문장형; 북토크 사인회 초청 인원은 어떻게 모집하나요?/선착순으로 모집합니다. • 왜-단답형; 연료전지 전기생산은 왜 기존 화력발전과 달리 악취나 대기오염물질이 발생하지 않나요?/연소방식이 아니기 때문에	
▣ 예/아니요형 • 긍정-단답형; 민원인은 원하는 날짜에 원하는 좌석을 예매했어?/응. • 긍정-문장형; 현재 기후동행카드는 사용하는 데 불편함이 있나요?/네, 경기도로 넘어갈 때는 하차하여 다시 승차해야 합니다. • 부정-단답형; 민원인의 상담은 전시와 관련된 상담입니까?/아니요. • 부정-문장형; 목동실내빙상장 지도자들의 자격증 번호를 알 수 있니?/아니, 개인정보이므로 공개하기가 어려워.	

6. 데이터 저장 구조 및 파일 명명 규칙

○ 디렉토리 구조

데이터	분류 (1단계)	분류 (2단계)	수량
민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터	하나카드	분류	36,435
		요약	21,557
		질의응답	18,812
	엘지유플러스	분류	20,100
		요약	14,624
		질의응답	9,196
	액티벤처	분류	5,000
		요약	3,934

		질의응답	2,743
--	--	------	-------

○ 파일 명명 규칙

- 원천데이터 : 수집기관_일련번호.json

예시) 하나카드_01.json

- 라벨링데이터 : 가공 유형_구분번호_가공순차번호.json

예시) 분류_200001_1.json

제2장 데이터 구축 및 활용

1. 데이터 구축

1.1 데이터 구축과정 및 결과

구축과정	세부 프로세스	내용	결과
데이터 수집/획득	1) 원시데이터 획득 2) 원본 음성 또는 텍스트 데이터 품질 확인	수집 기관으로부터 음성 데이터 또는 STT 전사 텍스트 데이터 인수	하나카드 8000건, 엘지유플러스 5,000건, 액티벤처 1,000건 인수
데이터 정제	1) STT 전사 또는 전사 텍스트 데이터 기계적 정제 2) 휴먼 정제 3) 비식별화 진행	전사 텍스트 정제 부적절한 표현 삭제 개인정보 비식별화 글자수 및 턴 수 확인 정제 작업 검사	원천데이터 12,303건 구축 목표(10,000건)대비 23% 초과 구축으로 가공 시 탈락 데이터 대비
데이터 가공 (라벨링)	1) 원문 텍스트 확인 2) 분류, 요약, 질의응답 가공 3) 전수 검수 4) 최종 검수	LLM의 Instruction Tuning을 위한 분류, 요약, 질의응답 가공	라벨링데이터 132,401건 구축 목표(100,000건)대비 32% 초과 구축
AI 모델 학습	1) LLM 선정 2) 구축 데이터 셋 유효성 검증	분류 성능 Recall@K 요약, 질의응답 성능 ROGUE-1, ROGUE-L	학습 135,265건, 테스트 10,000건, 검증 10,000건 유효성 지표/결과 - 분류: Recall@K / 튜닝 전후 성능 비교 4.59 - 요약: ROGUE-1 튜닝 전후 성능 비교 5.47 / ROGUE-L 튜닝 전후 성능 비교 4.97 - 질의응답: ROGUE-1 튜닝 전후 성능 비교 4.42 / ROGUE-L 튜닝 전후 성능 비교 3.45

1.2 데이터 구축 유의사항

구분	구축 유의사항
데이터 편향 및 윤리 준수	• 혐오·차별·성적 발언·비속어(욕설) 등 인공지능의 윤리 문제와 관련하여 문제의 소지가 있는 내용은 가이드라인에 비윤리적 표현에 해당 사례를 명시적으로 제시하여 수집하지 않음 • 국가나 인종 차별, 혐오 소지가 있는 내용이 포함되었는지 확인하고 해당 사례가 발견될 경우 명시적으로 제시하며, 특히 주의함 • 특정 개인이나 단체 등을 비방하는 내용을 포함하는 대화도 혐오나 차별, 반사회적 발언 등이 나타날 문제가 있는 경우도 위와 같은 방식으로 처리함.
수 집 민감 정보 및 개인정보 보호	• 획득/수집 단계에서부터 민감정보 및 개인정보는 비식별해야 함을 데이터 수집처에 공유하고 획득/수집되는 원시데이터는 민감정보 및 개인정보에 대한 음성 비식별화된 데이터로 수령함 • 하나카드 및 엘지유플러스는 외부 반출 이전에 음성 비식별화를 처리하고, 이와 관련한 기술 지원을 요청할 경우 데이터 제공처에 방문하여 음성 비식별화를 지원함 • 다음 단계에서 대화 생성자가 인지하지 못하고서 개인정보를 언급할 가능성이 있으므로 기계적 정제 및 인적 정제단계를 통해 철저히 개인정보 비식별화 정제를 진행함 • 외부 반출 전 개인정보 비식별화하는 과정에서는, NIA ‘인공지능 학습용 데이터 품질관리 가이드라인 v3.1’ 별권 초거대 AI 데이터 구축 사례를 참고하여 개인정보를 정제하며, 추가로 필요한 대상과 항목에 대해서는 개인정보보호위원회의 가이드를 중용함 • 정제 작업 도구의 개인정보 검사 기능으로 1차 필터링한 후 해당 항목은 정제 작업자가 비식별화 유무를 판단하여 비식별화 대상인 경우 비식별화하거나 납품 제외함 • 비식별화된 데이터 항목은 지정된 형식에 따라 마스킹 처리되고, 라벨링 단계에서 자동 어노테이션을 통해 처리 • 기계적 정제 단계에서 검출되지 않는 개인정보 항목을 포함할 수 있으므로 작업자를 통한 인적 정제 방식으로 최종적으로 검출하고 정제함

	사업수행계획서 및 데이터 구축요건 일치	사업수행계획서에 정의한 데이터 구축 기준에 맞추어 데이터를 획득/수집했는지 정기적으로 모니터링 및 검사하여 구축요건과 일치하게 함
	데이터 획득/수집 시 품질 고려	인공지능 학습용 데이터 품질관리 가이드라인 3.1의 데이터 획득/수집 품질기준 및 개인정보 가이드라인 준수 등 정제에 필요한 사항을 반영하여 품질기준을 확보함
	데이터 동기화	원시데이터를 기반으로 대화 데이터를 생성하므로 유니크한 ID로 관리함
	학습모델 구축목적의 적합성	데이터 설계 담당자, 학습모델 개발자가 초기 수집한 원시데이터를 검토하고 모델개발 목적에 부합하는지와 수집된 데이터의 제반 품질이 학습에 적합한지를 획득/수집의 초기에 검토하여 피드백하여 반영함
	개인식별정보 비식별화	- 이름의 경우 '▲▲▲'으로 모두 치환함. - 주소의 경우 구 이하 주소 삭제 진행함. - 각종 번호의 경우 자릿수에 맞춰 '▲'으로 치환하여 기재함.
정 제	욕설 및 비속어 정제	- 부적절한 표현의 범위 - 부적절한 표현이란'욕설 및 비속어, 혐오 및 차별 표현, 부정적인 평가 표현, 성적인 표현' 등을 말한다. 또한 혐오 및 차별 표현이란 성별, 종교, 나이, 사회적 신분, 출신 지역, 출신 국가, 출신 민족, 언어, 장애, 용모 등 신체조건, 임신 또는 출산, 가족 형태 또는 가족 상황, 인종, 경제적 지위, 피부색, 사상 또는 정치적 의견, 성적 지향, 성별 정체성, 병력, 징계, 성적 등을 이유로 차별하는 내용을 담어 언어 표현이다. - 위의 부적절한 표현인 혐오, 부정적인 평가, 차별 표현을 제거 시 문장의 전체 맥락이나 정확한 의도 파악이 어려울 경우 해당 데이터 자체를 가공 데이터에서 제외하도록 함. - 부적절한 표현 등에 대해서는 데이터 내에서 삭제를 진행하며 별도로 삭제 대상의 단어 및 문장에 대한 사전을 구축하여 지속적으로 활용하도록 함. - 문장에서 부적절한 표현을 삭제하더라도 문맥을 해치지 않는 경우에는 부적절한 표현에 대해서만 삭제를 진행하며, 부적절한 표현이 주 타깃용어로 단어 삭제 시 문맥을 해치는 경우 문장 자체를 삭제한다. - 구축된 사전을 기반으로 데이터의 생애주기별 품질검수 및 최종 품질에 대한 반복, 교차검수 진행

	텍스트 중복 검사	• 원천데이터별 유사한 문장과 단어 체크 기능 • 문장 내 단어 사용 횟수 체크 및 빈도수 높은 단어 포함 문장 확인 기능 • 중복여부 체크 시 80% 이상 항목 자동 선택 및 내림차순 정렬 표시 • 중복 문장 사전등록 기능, 사전에 등록된 문장과의 유사도 체크 기능														
가 공	Instruction 작성	• 명확한 질문 및 지시 사항: 명확한 질문 및 지시 사항을 정리하고 이를 프롬프트에 반영하여 작성 • 다양한 유형의 답변 유도: 다양한 유형의 답변을 얻을 수 있도록 여러 정보를 요청해야 하며, 상세한 정보나 생각이 담긴 답변을 위해 열린 질문을 사용 • 적절한 길이와 포맷: 불필요한 정보 없이 간결하고 읽기 쉬운 형식을 유지하며 , 너무 길지 않게 작성 • 대체 단어 사용: 다양한 측면을 포함한 답변을 얻기 위해 여러 형용사를 사용하여 작성														
	데이터 검수	<table><tr><th>항목</th><th>내용</th></tr><tr><td>instruction 지시문</td><td> • 지시문 유형과 지시문 내용의 일치 여부 확인 • 지시문 규격(1~3문장, 공백 제외 200자 이내)에 맞는지 확인 • 오타나 띄어쓰기 등 맞춤법 확인 </td></tr><tr><td>분류</td><td> • 민원 상담 내용과 부합하고 있는지 검토 </td></tr><tr><td>요약문</td><td> • 원문의 핵심 내용을 담고 있는지 검토 • 문장 품질 검토(문장 완성도, 오타나 띄어쓰기 등 맞춤법) • 지시문에 따른 규격 적합 여부 확인 </td></tr><tr><td>질의응답</td><td> • 지시문에 적합한 질문인지 검토 • 질문 유형에 맞는 답변인지 검토 • 문장 품질 검토(문장 완성도, 오타나 띄어쓰기 등 맞춤법) </td></tr><tr><td>메타정보</td><td> • 원천데이터-가공데이터-메타정보 일치 여부 확인 </td></tr><tr><td>데이터 중복</td><td> • 라벨링 데이터의 유사도를 측정하여 데이터 중복 방지 </td></tr></table>	항목	내용	instruction 지시문	• 지시문 유형과 지시문 내용의 일치 여부 확인 • 지시문 규격(1~3문장, 공백 제외 200자 이내)에 맞는지 확인 • 오타나 띄어쓰기 등 맞춤법 확인	분류	• 민원 상담 내용과 부합하고 있는지 검토	요약문	• 원문의 핵심 내용을 담고 있는지 검토 • 문장 품질 검토(문장 완성도, 오타나 띄어쓰기 등 맞춤법) • 지시문에 따른 규격 적합 여부 확인	질의응답	• 지시문에 적합한 질문인지 검토 • 질문 유형에 맞는 답변인지 검토 • 문장 품질 검토(문장 완성도, 오타나 띄어쓰기 등 맞춤법)	메타정보	• 원천데이터-가공데이터-메타정보 일치 여부 확인	데이터 중복	• 라벨링 데이터의 유사도를 측정하여 데이터 중복 방지
		항목	내용													
		instruction 지시문	• 지시문 유형과 지시문 내용의 일치 여부 확인 • 지시문 규격(1~3문장, 공백 제외 200자 이내)에 맞는지 확인 • 오타나 띄어쓰기 등 맞춤법 확인													
		분류	• 민원 상담 내용과 부합하고 있는지 검토													
		요약문	• 원문의 핵심 내용을 담고 있는지 검토 • 문장 품질 검토(문장 완성도, 오타나 띄어쓰기 등 맞춤법) • 지시문에 따른 규격 적합 여부 확인													
		질의응답	• 지시문에 적합한 질문인지 검토 • 질문 유형에 맞는 답변인지 검토 • 문장 품질 검토(문장 완성도, 오타나 띄어쓰기 등 맞춤법)													
	메타정보	• 원천데이터-가공데이터-메타정보 일치 여부 확인														
데이터 중복	• 라벨링 데이터의 유사도를 측정하여 데이터 중복 방지															

2. 학습모델

2.1 학습모델 및 알고리즘

○ 임무 정의

- 민간 민원 상담 내용을 기반으로 구축된 학습 데이터에 대해서 주제 분류, 요약 및 질의응답 서비스 제공을 위한 학습 모델 설계 및 구현

○ 임무 선정 사유

- 민원 상담 내용을 기반으로 한 자동 주제 분류, 요약 및 질의응답 등의 결과가 학습 모델을 통해 올바르게 생성되는지를 확인하여 구축 데이터에 대한 유효성을 검증

○ AI 모델에 대한 사전학습 여부

- 본 과제에서는 모델 유효성 검증을 위해서 사전학습을 진행하지 않고 파인튜닝 방식으로 모델을 개발
- 사전학습을 진행하지 않고 파인튜닝으로 진행한 사유

① 막대한 데이터 요구량

: 사전 학습을 하려면 방대한 양의 데이터가 필요합니다. 예를 들어, 대규모 언어 모델(LLM)의 경우 수백 기가바이트(Gigabytes)에서 페타바이트(Petabytes) 규모의 텍스트 데이터가 필요할 수 있으며 데이터의 전처리 과정도 복잡하며, 중복 제거, 정제, 품질 관리 등을 수행해야 함

② 고성능 하드웨어 필요

: 사전 학습에는 일반적으로 수백에서 수천 개의 GPU 또는 TPU가 필요함. 예를 들어, GPT-3는 1750억 개의 매개변수를 가지고 있으며, 이를 학습하는데 수천 개의 A100 GPU를 사용하였습니다. 소규모 과제에서는 감당하기 어려운 비용이 발생을 고려했음

③ 긴 학습 시간

: 사전 학습을 제대로 수행하려면 학습률, 배치 크기, 옵티마이저 등의 하이퍼파라미터를 신중하게 조정해야 하고 잘못된 설정은 비효율적인 학습을 초래

하며, 학습이 실패할 수도 있음. 따라서 사전 학습은 고성능 하드웨어를 갖추었다고 하더라도 몇 주에서 몇 달이 걸릴 수 있고 중간에 오류가 발생하면 재훈련이 필요하며, 이는 추가적인 비용과 시간을 초래함


○ 모델 선정 과정

- 모델리소스 및 자원 활용: 고성능 GPU 서버를 사용하여 모델 학습을 진행
- 모델 개발: 1-Cycle 자가 점검 계획에 맞춰 후보 모델 개발
- 자가 점검 성능 지표 결과를 통해 후보 모델 중 각 태스크 별로 가장 성능이 우수한 모델 최종 선정

○ 최종 선정 모델

• 분류 모델 : Meta-Llama-3-8B-Instruct

- * LLAMA3 모델은 메타의 AI 그룹이 개발한 차세대 사전 훈련된 대규모 언어 모델(LLM)
- * 128K 토큰의 vocabulary 적용
- * 사전학습과 강화 학습 과정의 개선을 통해 추론, 코드 생성 및 지시 수행 등의 능력이 기존 모델 대비 대폭 향상
- * Grouped Query Attention(GQA)을 통해 추론 효율성 개선
- * 파라미터 개수에 따라 다양한 모델 크기를 제공




• 요약 및 질의응답 모델 : openchat-3.5-0106(mistral)

* OpenChat 모델은 C-RLFT 방법론을 사용해 파인튜닝한 오픈 소스 언어 모델

* C-RLFT 방법론은 이미 라벨링된 다양한 품질(고품질과 저품질)의 데이터를 활용하여 클래스 조건화 데이터셋을 구축하고 표준 RLHF 방법론과 유사하게 보상을 최대화하는 방식으로 학습

* OpenChat 최신 모델은 Mistral 과 Gemma을 기본 모델로 한 파인튜닝 모델을 제공

* 최근에 OpenChat-3.5 의 업그레이드 버전이 출시되었으며 다양한 벤치마크에서 뛰어난 성능을 보임. 한국어의 성능도 우수함





2.2 모델 학습 준비 및 유효성 검증 결과

○ 개발 환경

구분	내용
구성방식	도커 컨테이너
CPU	Intel(R) Xeon(R) Silver 4210R CPU @ 2.40GHz
Memory	128G
GPU	NVIDIA A100 40G*2
Storage	3.5T
OS	CentOS Stream release 9

○ 학습조건

구분	내용
개발언어	Python=3.11
프레임워크	CUDA=12.4, Pytorch=2.2.0
학습 데이터	Training Set – 약 80%(원천 기준 115,265건) Validation Set – 약 10%(원천 기준 1,000건) Test Set – 약 10%(원천 기준 1,000건)

학습 알고리즘	LoRA Fine Tuning • LoRA는 모델 전체를 업데이트하지 않고, 일부 파라미터에 대해 저차원 행렬을 추가적으로 학습시켜 빠르고 효율적인 파인튜닝 수행 • 기존 모델의 원래 가중치는 고정되고, 저차원 행렬만 학습하여 학습할 파라미터 수가 줄어들어 효율적인 학습이 가능 • 기존의 전체 모델 파라미터를 업데이트하는 방식보다 메모리와 계산 비용이 크게 감소 Linear Projection  LoRA adaptation 
주요 학습 조건	epoch=5 batch size=1 initial lr=1.1179251066632773e-05 weight decay=0.1 optimizer=paged_adamw_32bit lora r=8 lora alpha=16 lora dropout=0.05 lora target modules=["q_proj", "v_proj", "k_proj", "o_proj"]

○ 유효성 검증 방법

구분	내용
----	----

분류	- Recall@K • 분류 태스크는 Recall@K 지표를 사용하여 유효성 검증 및 튜닝 전후 성능 비교 • Recall 은 분류 모델에 일반적으로 사용하는 모델로서 올바르게 분류했는지를 측정하는 지표 • Recall(재현율)은 올바르게 분류된 양성의 비율로 민감도 및 적중률 이라고도 함 • Recall@K는 모든 정답 중에서 기계가 분류한 아이템 K개가 얼마나 포함되는지 비율을 의미 $recall = \frac{\text{correctly classified positives}}{\text{total number of positives}}$
요약 및 질의응답	- ROGUE-1, ROGUE-L 지표 • 요약 및 질의응답 태스크는 ROGUE 지표를 사용하여 유효성 검증 및 튜닝 전후 성능 비교 • ROGUE는 Recall-Oriented Understudy for Gisting Evaluation 의 준말로 텍스트 생성 모델의 성능 평가 지표 • ROGUE-N은 생성된 요약 문장과 참조 요약 문장 사이의 겹치는 n-gram(단어나 구문)을 비교하는 방식으로 성능을 측정하며 ROGUE-1은 단일 단어 수준에서 이를 평가 • ROGUE-L은 LCS(Longest common subsequence) 기법을 이용해 최장 길이로 매칭되는 문자열을 측정. LCS의 장점은 ROGUE-2와 같이 단어들의 연속적 매칭을 요구하지 않고, 어떻게든 문자열 내에서 발생하는 매칭을 측정하기 때문에 보다 유연한 성능 비교가 가능 $\begin{aligned} \text{ROUGE-N} &= \frac{\sum_{S \in \{\text{ReferenceSummaries}\}} \sum_{gram_n \in S} \text{Count}_{match}(gram_n)}{\sum_{S \in \{\text{ReferenceSummaries}\}} \sum_{gram_n \in S} \text{Count}(gram_n)} \quad (1) \end{aligned}$ • ROGUE-1 과 ROGUE-L 중 높은 성능 지표 값으로 평가 진행 $\begin{aligned} R_{lcs} &= \frac{LCS(X, Y)}{m} \\ P_{lcs} &= \frac{LCS(X, Y)}{n} \\ F_{lcs} &= \frac{(1 + \beta^2) R_{lcs} P_{lcs}}{R_{lcs} + \beta^2 P_{lcs}} \end{aligned}$

4) 유효성 검증 결과

'24년 초거대AI 확산 생태계 조성 활용 가이드라인(민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터) v1.0

항목명	측정 지표	정량 목표	결과값			
분류 성능 비교 (Tuning전후)	Recall@K	4% 이상	구분	튜닝 전	튜닝 후	성능 비교
			Recall@K	48.31	52.90	4.59
	튜닝 전	Total items processed: 10000 Classification-Evaluation(Recall@1 micro average): 3300 test data - ('precision': 0.4831914853617021, 'recall': 0.4831914853617021, 'f1': 0.4831914853617021)				
	튜닝 후	10000 items processed Classification-Evaluation(Recall@1 micro average): 3300 test data - ('precision': 0.5290697674418605, 'recall': 0.5290697674418605, 'f1': 0.5290697674418605)				
요약 성능 비교 ⁴⁾ (Tuning전후)	Rouge-1/Rouge-L	4% 이상	구분	튜닝 전	튜닝 후	성능 비교
			Rouge-1	68.37	73.84	5.47
			Rouge-L	57.30	62.27	4.97
	튜닝 전	Total items processed: 10000 Summary-Evaluation(Rouge): 3400 test data - ('rouge1': 0.6837010125197474, 'rouge2': 0.5524989815034049, 'rougeL': 0.5730522863210391, 'rougeLsum': 0.5545878195035079)				
	튜닝 후	Total items processed: 10000 Summary-Evaluation(Rouge): 3400 test data - ('rouge1': 0.7384733168291049, 'rouge2': 0.6237949236165424, 'rougeL': 0.6227862013528209, 'rougeLsum': 0.6228093361043616)				
질의응답 성능 비교 ⁵⁾ (Tuning전후)	Rouge-1/Rouge-L	4% 이상	구분	튜닝 전	튜닝 후	성능 비교
			Rouge-1	48.88	53.30	4.42
			Rouge-L	45.97	49.42	3.45
	튜닝 전	Total items processed: 10000 QA-Evaluation(Rouge): 3300 test data - ('rouge1': 0.4888654534967059, 'rouge2': 0.37424740104839316, 'rougeL': 0.45972697920072264, 'rougeLsum': 0.4407422502017653)				
	튜닝 후	Total items processed: 10000 QA-Evaluation(Rouge): 3300 test data - ('rouge1': 0.5330575348458657, 'rouge2': 0.4164256722470054, 'rougeL': 0.4942200719215796, 'rougeLsum': 0.4913940384050639)				

3. 서비스 활용

3.1 서비스 활용 예시 및 시나리오

- 서비스 개발: 민원 상담 텍스트 데이터에 대한 Instruction tuning data를 통해 주제 분류 및 요약 서비스를 위한 LLM 모델을 개발함으로써 분석, 챗봇 서비스 등 다양한 서비스에 활용 가능할 것으로 기대됨
- 사업화 방안: 다양한 분야의 제품 개발 및 판매, 부가가치 창출 가능
 - 데이터 분석: 민원 상담 텍스트 데이터를 활용하여 데이터 분석 및 인사이트 도출 서비스 제공
 - 감정 분석 및 사용자 만족도 측정: 민원 상담 데이터를 기반으로 감정 분석을 수행하여 사용자의 감정과 태도를 이해하고, 상담 결과에 대한 사용자 만족도를 측정하는 서비스를 제공
 - 개인화된 서비스 제공: 민원 상담 텍스트를 기반으로 사용자의 선호도와 관심사를 파악하여 개인화된 서비스를 제공
 - 교육 및 훈련 서비스: 민원 상담 텍스트 데이터를 활용하여 상담원의 교육 및 훈련을 지원하는 서비스를 제공
 - 피드백 및 개선 프로세스: 민원 상담 텍스트 데이터를 활용하여 상담 서비스의 피드백 및 개선 프로세스를 지원하는 서비스 제공
- 활용 방안 및 계획

국립아시아문화전당은 고객 서비스개선과 콜센터 운영 효율성을 확보하기 위해 AI 도입을 추진합니다. 공공기관의 특성상 고객 상담의 민감성을 고려하여, AI 모델의 기술적 신뢰성을 철저히 검증 후, 상담원의 고객상담 시 관련 정보를 빠르게 제원하는 방식으로 활용할 예정입니다.

① 분류 서비스

- AI가 민원 유형을 자동으로 분류하고 분석하여, 경영진과 관리자가 신속하고 효율적인 의사결정을 하는 데 활용 예정
- 상담원의 민원응대 품질 향상과 고객의 불만 사항을 신속하게 해결하는 데 활용



<국립아시아문화전당 활용 : AI 분류 모델 대시보드(예시)>

② 요약 서비스

- 민원 상담 데이터를 AI가 요약하여 집중적인 문제 식별 및 해결에 활용
- 고객의 요구사항 및 서비스 관련 주요 이슈를 신속하게 파악하고, 적절한 조치를 재빨리 취할 수 있도록 정리된 리포트로 인사이트 도출
- AI 요약기능 개발, 리포트 생성 자동화, 실시간 데이터 분석 및 피드백 반영 등 추가



<국립아시아문화전당 활용 : AI 요약 모델 대시보드(예시)>

③ 대화 서비스

- 상담원 업무지원을 시작으로 점진적으로 독립적인 고객 민원응대로 서비스 확장
- 초기단계(2024): 상담원 업무지원을 위한 AI Assistant 활용
- 고도화단계(2025) : AI 상담원 시범운영 및 콜센터 운영시간 확대 추진
- 최종단계(2026): 고객 맞춤형 서비스 제공

3.2 데이터 성능 향상 계획

· 대용량 모델 활용을 통한 성능 향상

- 모델 규모 확대: 이번 과제에서는 7B, 8B 모델을 사용하였지만, 70B 모델과 같은 대규모 모델로 전환하면 더 복잡한 패턴을 학습하고 더 정교한 응답을 생성할 수 있음. 이는 특히 고차원적인 문제 해결, 창의적 텍스트 생성, 그리고 더 정확한 예측 능력을 요구하는 작업에서 큰 성능 향상을 가져올 수 있음.
- 리소스 최적화: 대용량 모델은 더 많은 컴퓨팅 리소스를 필요로 하므로, 분산 학습,

모델 병렬화, 혹은 효율적인 하드웨어 활용 전략을 통해 리소스 사용 최적화 필요.
이를 위해 TPU/GPU 클러스터를 활용하거나, 모델 압축 기법(예: 양자화, 프루닝)
을 적용할 수 있음

· 프롬프트 엔지니어링을 통한 성능 최적화

- 프롬프트 설계 개선: 프롬프트 엔지니어링을 통해 모델의 출력 품질을 더욱 향상시킬 수 있음. 예를 들어, 체인 오브 사고(Chain-of-Thought) 기법을 활용하여 모델이 문제를 단계적으로 해결하도록 유도하거나, 샷러닝(Few-shot, Zero-shot, Chain-of-thought prompting)을 통해 문제 해결 과정의 논리를 향상하거나, 어댑티브 프롬프트(adaptive prompt) 등을 통해 유저의 피드백을 반영하여 동적으로 최적화하는 등 다양한 최적화 기법들을 적용하여 성능을 끌어낼 수 있음
- 프롬프트 기반 출력 검증: 메타 프롬프트(meta-prompt)와 같은 기법을 사용하여 모델의 출력 품질을 자체적으로 검토하도록 유도하거나 자동 평가 메커니즘(Auto-evaluation mechanisms) 등을 통해 모델 스스로 신뢰도를 판단하는 기능 추가하여 성능을 향상시킬 수 있음
- 자동화된 프롬프트 최적화: 프롬프트 엔지니어링을 자동화하는 도구나 프레임워크를 개발하여, 다양한 작업에 대해 최적의 프롬프트를 자동으로 생성하고 테스트할 수 있습니다. 이를 통해 모델의 응답 정확성과 일관성을 높일 수 있음

· LLM Reviewer 모델 도입을 통한 유효성 검증 강화

- 리뷰어 모델 추가: LM이 생성한 응답을 평가하고 개선하기 위해 별도의 LLM Reviewer 모델을 도입할 수 있으며, 이 리뷰어 모델은 생성된 텍스트의 일관성, 정확성, 그리고 논리적 타당성을 평가하여 최종 출력의 품질을 높일 수 있음
- 다단계 검증 프로세스: 리뷰어 모델을 활용하여 다단계 검증 프로세스를 설계. 예를 들어, 1차 모델이 생성한 출력을 리뷰어 모델이 검토하고, 필요시 수정하거나 재생성하도록 유도할 수 있으며 이를 통해 오류를 최소화하고 출력의 신뢰성을 높일 수 있음

'24년 초거대AI 확산 생태계 조성 활용 가이드라인(민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터) v1.0

- 인간-모델 협업: 리뷰어 모델의 출력을 인간 검토자와 협업하여 최종 결정을 내리는 방식으로 발전시킬 수 있음. 이를 통해 모델의 한계를 보완하고, 더 높은 수준의 정확성을 달성할 수 있음

별첨 1. 데이터 구축 현황표

- 시트 1 : 공모서(RFP)

<작성

요령

>

- 공모서 내 데이터별 RFP를 기준으로 양식의 항목별(데이터 개요, 구성 등) 내용을 요약하여 작성

※ 양식은 배포된 데이터 구축 현황표(엑셀)를 사용

13-23.민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터/

공모서(RFP)	
1. 데이터 개요	- 민간 분야 민원 상담 텍스트 데이터 - 데이터 구성 (원천데이터) 민간 민원 상담 기반 텍스트 데이터 1만 건 이상 (가공데이터) Instruction tuning data 10만 건 이상 ※ 민원 상담 주제 분류, 요약 태스크 필수 포함 - AI 일류(예시) - 민원 상담 내용을 기반으로 한 자동 주제 분류 및 요약 서비스 제공
2. 데이터 구성	원천 데이터 (원천데이터) 민간 민원 상담 기반 텍스트 데이터 1만 건 이상 - 민간 민원 상담 기반 텍스트 데이터 1만 건 이상 - 최소 3행 이상 상담 질의, 답변으로 구성 1건당 500글자 이상으로 구성 '네', '아니오', '감사합니다'와 같은 단순 답변은 건수 미포함
	라벨링 데이터 (가공데이터) Instruction tuning data 10만 건 이상 ※ 민원 상담 주제 분류, 요약 태스크 필수 포함
	메타 데이터 - 다음의 필수 정보를 포함하여 데이터 용세에 필요한 메타데이터 구축방안 제시 - 상담 일시 등 기본 정보 - 기타 명시되지 않은 사항은 데이터 구축 목적을 달성할 수 있도록 메타데이터를 구체화하여 제시
3. 데이터 구축방법	데이터 수집방법 - 다음 사항을 포함한 원천데이터 수집 방안 제시 - 실제 민원 내용을 기준으로 현실성 있는 대화 내용으로 구성 - 구체적인 데이터 수집 방법 - 기 구축데이터와의 차별성 및 중복 검증 방안 - 원천데이터의 지식재산권 해결 방안 및 비용을 포함한 구체적 데이터 획득 방법 마련 및 제시 - AI 알고리즘 편향 방지를 위한 데이터 수집 방안 마련 및 제시 - 그 이외의 데이터 수집을 위한 절차, 장소 및 도구(HW-SW), 조직, 기준 등이 포함된 수집 계획 제시
	데이터 가공 방법 - Instruction tuning data 10만 건 이상 - 민원 상담 주제 분류, 요약 태스크 필수 포함 - 민간 민원 상담 내용으로 기반으로 한 적절한 분류 방안 제시 - 대화 데이터 유형에 따른 차이(대화 길이 등)를 고려한 효율적인 데이터 요약 방안 제시 - 요약 데이터의 적정성을 증명할 수 있는 방안 제시 - 태스크별 편향 없이 구축되도록 설계 방안 제시 - LLM 학습에 적합한 라벨링 방법 구체적으로 제시 - 데이터 구축 및 활용목적 등을 고려하여 데이터 구성에 적합한 라벨링 방법 제시 - 그 이외의 고품질의 데이터 구축을 위한 최적의 라벨링 방법 제시

- 시트 2 : 사업수행계획(요약)

<작성

요령

>

- 사업수행계획서 최종본을 기준으로 양식의 항목별(데이터 개요, 목표량 등) 내용을 요약하여 작성

※ 양식은 배포된 데이터 구축 현황표(엑셀)를 사용

구축계획	구축 데이터 개요		○ 민원 상담을 필요로 하는 기업, 단체, 기관의 상담 지원 업무, AI 자동 상담 서비스 품질 향상에 기여하는 LLM Tuning 데이터셋 구축 및 제공																
	구축 목표량 (AI허브 개방 기준)		1. 분류 Instruction tuning data 3만 건(4. 분류 Instruction tuning data 2만 건 추가 구축) 2. 요약 Instruction tuning data 4만 건 3. 질의응답 Instruction tuning data 3만 건																
	구축 데이터 정의 (AI허브 개방 기준)	원천 데이터	데이터 유형/포맷	텍스트 / json															
			데이터 규모/객체수	12,303건 / 총 3,580,857어절															
		라벨링 데이터	라벨링 유형/포맷	분류, 요약, 질의응답 / json															
			라벨링데이터 규모(예. 파일 수)	132,401건 (대화형 민원상담 원천데이터를 대상으로 분류, 요약, 질의응답 가공 라벨링 정보를 담고 있는 json 파일)															
		메타 데이터	메타데이터 구조 및 포맷	JSON															
			메타 데이터 규모(예. 파일 수)	132,401건 (수집 출처, 상담날짜, 상담자 연령, 성별, 상담 주제 키워드 분류정보로 구성된 파일)															
	구축과정 단계별	획득/수집	원시데이터 획득/수집 방안 (데이터 유형/포맷/규모)	○ 구매 : 하나카드(카드사), 엘지유플러스(통신사), 액티벤처(여행사) 데이터 구매 (6천만원, 200,000건의 음성 파일 중 선별하여 텍스트화)															
		정제	원천데이터 분포 명세	<table><tr><th>수집처</th><th>건수</th><th>비율</th></tr><tr><td>하나카드</td><td>76,804</td><td>58.01%</td></tr><tr><td>엘지유플러스</td><td>43,920</td><td>33.17%</td></tr><tr><td>액티벤처</td><td>11,677</td><td>8.82%</td></tr><tr><td>합계</td><td>132,401</td><td>100%</td></tr></table>		수집처	건수	비율	하나카드	76,804	58.01%	엘지유플러스	43,920	33.17%	액티벤처	11,677	8.82%	합계	132,401
수집처		건수	비율																
하나카드	76,804	58.01%																	
엘지유플러스	43,920	33.17%																	
액티벤처	11,677	8.82%																	
합계	132,401	100%																	
학습	적용 모델 (알고리즘 표시)	○ 분류 모델 : Meta-Llama-3-8B-Instruct ○ 요약 및 질의응답 모델 : openchat-3.5-0106(mistral)																	

- 시트 3 : 데이터 구축 현황

<작성

요령

>

- 구축사업 수행 중에 작성 및 현행화했던 “데이터 파일 구축 현황표”의 최종본을 붙임으로 추가

※ 양식은 배포된 데이터 구축 현황표(엑셀)를 사용

구축 계획	구축 데이터 개요	o 민원 상담을 필요로 하는 기업, 단체, 기관의 상담 지원 업무, AI 자동 상담 서비스 품질 향상에 기여하는 LLM Tuning 데이터셋 구축 및 제공
	구축 목표량 (AI허브 개방 기준)	1. 분류 Instruction tuning data 3만 건(4. 분류 Instruction tuning data 2만 건 추가 구축) 2. 요약 Instruction tuning data 4만 건 3. 질의응답 Instruction tuning data 3만 건

원시 데이터											
설명	유형	형식	수량	단위	획득방법	AI허브 제출 여부					
하니카드	음성	.wav	30,000	건	구매	X					
엘지유플러스	음성	.wav	170,000	건	구매	X					
엑티벤처	텍스트	.txt	10,000	건	구매	X					
* 제출여부와 상관없이 원시데이터 보관은 5년 필수											
Training - 최종 학습용 데이터 (원천 데이터 + 라벨링 데이터)											
원천 데이터						라벨링 데이터					
설명	분류(1단계)	분류(2단계)	분류(3단계)	형식	수량	단위	라벨링 유형	개체수	형식	파일 수량	파일 비율
민간 민원 상담 Instruction tuning 데이터	하니카드	-	-	.json	5,757	건	분류	28,797	.json	28,797	1 : 1
						건	요약	17,103	.json	17,103	1 : 1
						건	질의응답	15,439	.json	15,439	1 : 1
	엘지유플러스	-	-	.json	3,216	건	분류	16,080	.json	16,080	1 : 1
						건	요약	11,690	.json	11,690	1 : 1
						건	질의응답	7,497	.json	7,497	1 : 1
	엑티벤처	-	-	.json	800	건	분류	4,000	.json	4,000	1 : 1
						건	요약	3,164	.json	3,164	1 : 1
						건	질의응답	2,196	.json	2,196	1 : 1
Validation - 최종 학습용 데이터 (원천 데이터 + 라벨링 데이터)											
원천 데이터						라벨링 데이터					
설명	분류(1단계)	분류(2단계)	분류(3단계)	형식	수량	단위	라벨링 유형	개체수	형식	파일 수량	파일 비율
민간 민원 상담 Instruction tuning 데이터	하니카드	-	-	.json	776	건	분류	3,888	.json	3,888	1 : 1
						건	요약	2,112	.json	2,112	1 : 1
						건	질의응답	1,923	.json	1,923	1 : 1
	엘지유플러스	-	-	.json	384	건	분류	1,920	.json	1,920	1 : 1
						건	요약	1,406	.json	1,406	1 : 1
						건	질의응답	827	.json	827	1 : 1
	엑티벤처	-	-	.json	100	건	분류	500	.json	500	1 : 1
						건	요약	373	.json	373	1 : 1
						건	질의응답	267	.json	267	1 : 1
Test - 최종 학습용 데이터 (원천 데이터 + 라벨링 데이터)											
원천 데이터						라벨링 데이터					
설명	분류(1단계)	분류(2단계)	분류(3단계)	형식	수량	단위	라벨링 유형	개체수	형식	파일 수량	파일 비율
민간 민원 상담 Instruction tuning 데이터	하니카드	-	-	.json	750	건	분류	3,750	.json	3,750	1 : 1
						건	요약	2,342	.json	2,342	1 : 1
						건	질의응답	1,450	.json	1,450	1 : 1
	엘지유플러스	-	-	.json	420	건	분류	2,100	.json	2,100	1 : 1
						건	요약	1,528	.json	1,528	1 : 1
						건	질의응답	872	.json	872	1 : 1
	엑티벤처	-	-	.json	100	건	분류	500	.json	500	1 : 1
						건	요약	397	.json	397	1 : 1
						건	질의응답	280	.json	280	1 : 1

- 시트 4 : S3 데이터 파일 현황

<작성

요령

>

- 최종데이터 업로드 완료 이후 작성한 “S3 데이터 파일 현황” 최종본을 붙임으로 추가

※ 양식은 배포된 데이터 구축 현황표(엑셀)를 사용

구축연도	과제번호	과제명	데이터번호	데이터명	s3버킷명
2024	13	민간 상담 LLM 사전학습 및 Instruction Tuning 데이터	23	13-23 민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터	aidata-2024-13-23 민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터/

품질보전조치, 개인정보 비식별 등 인 제 작업 완료 이후, S3 버킷 내 2. 최종산출물/1. 데이터/에 업로드된 최종 데이터 대상으로 데이터 파일 수량 확인 관리	수행계획서 내 세부데이터별 목표량 다수일 경우, row별 나눠서 기입 (원천데이터와 더불어 라벨링 목표량까 지 포함하여 기입)	품질검증 결과 보완 필요 데이터 여부 *미달성 : 0 *달성 : 오류가 1건이라도 발견되면 0	품질보전조치 완료 후 최종데이터 업로드 여부 확인을		개인정보 비식별 완료 후 최종데이터 업로드 여부 확인을	과업 수행 결과가 수행계획서 목표량을 달성했는지 여부 (정상 과업 종료시, 일괄 달성이 정상)
하위경로	목표량 (수행계획서)(단위)	품질검증(TTA) 결과 보완조치 대상 여부 (0/X)	품질보전조치 완료 여부 (0/X)	개인정보 비식별 조치 대상 여부 (0/X)	개인정보 비식별 조치 완료 여부 (0/X)	구축과제 목표량 달성 여부 (0/X)
23. 민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터//2. 최종산출 물/1. 데이터/	원천데이터 10,000건	0	0	0	0	0


'24년 초거대AI 확산 생태계 조성 활용 가이드라인(민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터) v1.0


개인정보 비식별 완료 후 최종데이터 업로드 여부 확인용	과업 수행 결과가 수행계획서 목표량을 달성했는지 여부 (정상 과업 종료시, 일괄 달성이 정상)	구축 후 업로드한 S3 데이터 파일 수량이 수행계획서 목표량과 일치하는지 여부	P열에 대한 상세 사유 기입	Training + val + test 폴더 내 데이터 총합		용량은 GB 단위 기입 (1GB 미만시, MB 단위 기입)	
		예시에서는 목표량 중 라 벨링 30만장 대비 라벨링 수량 총합 12만장 으로 불일치	P6에 대한 사유 상세 기술	총합			
개인정보 비식별 조치 완료 여부 (O/X)	구축과제 목표량 달성 여부 (O/X)	총 구축 데이터 파일 수량의 목표량 일치 여부 (O/X)	총 구축 데이터 파일 수량이 목표량 대비 상이한 경우 사유	원천데이터 수량 총합	라벨링데이터 수량 총합	원천데이터 용량 총합	라벨링데이터 용량 총합
O	O	O	목표량 충족	12,303	132,401	40.73MB	889.99MB


원천데이터 폴더 내에 여러 파일 확장자들 중, 원천데이터로 기능하는 (ex. .jpg 등) 주요 확장자 기입	라벨링데이터 폴더 내에 여러 파일 확장자들 중, 라벨링데이터로 기능하는 (ex. .json 등) 주요 확장자 기입	파일 수량은 천원 단위 절삭 등 금지 (천제 수량 기입 필수)	용량은 GB 단위 기입 (1GB 미만시, MB 단위 기입)	과제 특성상, 해당 구성이 불가한 경우 (NIA 담당자와 상의 必) 외에는 Training : val : test = 8 : 1 : 1 비율 필수				
		Training				Validation		
주요 원천데이터 파일 확장자	주요 라벨링데이터 파일 확장자	원천데이터 수량	원천데이터 용량	라벨링데이터 수량	라벨링데이터 용량	원천데이터 수량	원천데이터 용량	라벨링데이터 수량
json	json	9,773	32.25MB	105,966	706.11MB	1,260	3.99MB	13,216

					Other 폴더 내 포함된 메타데이터 수량		Sample 데이터 가이드라인 참고				원천 : 라벨링 데이터 파일 간 관계
	Test				Other수량		Sample				
라벨링데이터 용량	원천데이터 수량	원천데이터 용량	라벨링데이터 수량	라벨링데이터 용량	메타데이터 수량	메타데이터 용량	원천데이터 수량	원천데이터 용량	라벨링데이터 수량	라벨링데이터 용량	데이터 형태
87.07MB	1,270	4.49MB	13,219	96.81MB			5	13.2KB	50	281.28KB	1:多

데이터) v1.0







'24년 초거대AI 확산 생태계 조성 활용 가이드라인(민간 민원 상담 LLM 사전학습 및 Instruction Tuning 데이터) v1.0

3 The project will be supported