

발표주제 - 인공지능과 자율성

근 10년 사이 알파고, ChatGPT 등과 같은 인공지능이 쏟아져 나오며 "인공지능은 자율적 존재인가?"라는 SF 소설이나 철학회에나 등장할 법한 질문이 현실적인 논쟁으로 부상하기 시작했습니다. 이에 대한 논쟁이 다른 것들에 비하여 더 치열한 까닭은 과학기술이 생명의 창조라는 신적인 권능에 근접하였다고도 느낄 법한 상징성도 있겠지만, 그것보다도 이 질문이 자율적인 인공지능이 야기할 수많은 잠재적인 문제를 풀 실마리이기 때문일 것입니다. ChatGPT와 같은 LLM 모델은 화두에 오른 지 10년도 채 되지 않았지만, 사람들의 생활양식을 이전과는 비교도 할 수 없을 정도로 비가역적으로 바꾸어 놔습니다. 앞으로 인공지능이 기존의 사회 시스템에 녹아들면서 가져올 변화는 긍정적인 부분도 당연히 많을 것입니다. 그러나, 트롤리 딜레마 문제와 같이 가져올 혼란도 상당할 것입니다. 인공지능의 자율성에 대한 철학적 논쟁은 윤리적인 문제를 넘어 이러한 혼란과 그에 따르는 사회적 비용을 줄이는데 기여할 것입니다.

이러한 논쟁을 결론짓기 위해서는 인공지능이 무엇인지부터 명확히 할 필요가 있습니다. 우선, 현대의 인공지능은 바둑, 작문, 그림 생성과 특정한 목적을 달성하기 위하여 설계된 철저히 도구적인 객체입니다. 이러한 특성에 의거하여 "현대의 인공지능은 합목적적인 객체이기 때문에, 자율성이 없다"는 가정을 하고 논지를 전개하겠습니다.

현대의 인공지능은 특정한 목적을 달성하기 위하여 특수한 방법론과 데이터에 의해 설계됩니다. 그렇기에 설계 범위를 벗어나는 영역의 작업을 수행할 수는 없습니다. 그 예시로, ChatGPT를 아무리 학습시킨다 한들 이세돌과 대국을 시킬 수는 없으며, 거꾸로 알파고도 프로그래머 대신에 코드를 짜거나 질문에 대답해줄 수는 없다는 것입니다. 이러한 사실은 지금의 인공지능을 자율적 존재라고 가정할 경우, 매우 부자연스러운 일입니다. 만약 그렇다면, 인공지능이 목적을 달성하기 위한 수단 뿐만 아니라 궁극적인 목적 또한 능동적으로 선택할 수 있어야 하나 그러지 못하기 때문입니다. 인간이 끊임없이 학습을 통해 주어진 환경에 적응할 수 있는 것과는 대조적입니다. 흔히들 자율주행 자동차가 교차로에서 좌회전을 결정하거나, 앞차와의 거리를 자동으로 조절하는 모습을 인공지능이 가진 자율성의 예시로 들곤 합니다. 하지만 이러한 행동들은 실제 자유의지의 발현이라기보다는, 미리 주어진 목표를 달성하기 위해 수학적으로 최적화된 결과에 가깝습니다. 인공지능의 수학적 최적화는 사전 정의된 알고리즘 범위를 벗어나지 못합니다. 경로 계산이나 자원 배분과 같은 작업에서도 이 원칙은 동일하게 적용됩니다. 이는 인간이 배고픔이나 수면 욕구와 같은 생리적 충동을 해결하기 위해 즉흥적 판단과 환경 적응을 결합

하는 방식과 질적으로 다릅니다. 이처럼 인공지능은 그 이름과는 다르게 인간의 지능이 가지는 다면적인 성질의 편린만을 모사하고 있습니다. 이러한 맥락 없이 현대 인공지능의 피상적인 측면만을 살펴보면, 그것은 그림도 잘 그리고, 대화도 잘 하고, 바둑도 잘 두는 백마 탄 초인인 것처럼 보입니다. 그러나, 실체는 입력 데이터 간의 관계를 계산하고, 가중치를 부여하여 생성한 확률 분포로 다음 출력을 예측하는 수학적 모델에 불과합니다. 지금의 인공지능은 본질적으로는 그림을 그리고 대화도 하는 무언가가 아니라 복잡한 알고리즘이 적용된 인형뽑기 기계에 가깝습니다. 그렇기에 현재의 인공지능은 자율적인 존재라고 보기 어렵습니다.

그러나 '자유의지'의 핵심을 '욕망에 따른 행동'으로만 규정하는 데는 한계가 있습니다. 위 가설제기 문단은 자유의지의 개념을 실질적으로 "욕망에 따라 행동하는 능력"¹으로서 정의하고 있습니다. 인공지능에는 자유의지가 없다고 주장하는 사람들의 말을 들어보면, 인공지능은 욕망을 가지지 않기 때문에 목적을 내재적으로 설정할 수 없고, 그렇기에 인공지능은 자유의지가 없다는 주장하는 셈입니다. 그러나, 위 자유의지의 정의에는 근본적으로 "욕망을 선택할 수 있는가"², 즉 욕망에 관한 욕망을 가지고 있는지에 대한 대답이 빠져 있습니다. 인간이 진정으로 자유의지를 가진 존재라면, 스스로 무엇을 욕망할 것인지조차도 스스로의 의지로 선택할 수 있어야 합니다. 그러나, 2019년 독일 막스 플랑크 연구소의 실험에 따르면, 어떤 판단을 할 때, 스스로 결정했다고 생각한 시점보다 10초나 먼저 신경 반응이 일어났다는 사실이 밝혀졌습니다.³ 이 실험 결과는 우리에게 자유의지로 여겨지는 판단이 실제로는 생화학적 과정에 선행적으로 결정된 결과일 수 있음을 암시합니다. 우리는 자유의지대로 판단했다고 생각하지만, 실제로는 그렇다고 착각하고 있을지도 모른다는 것입니다. 이러한 발견은 인간의 의사결정이 의식하기 전에 이미 뇌의 생화학적 과정에 의해 형성된다는 점을 시사하며, 결국 뇌의 사고 과정과 인공지능의 계산 방식 사이에 구조적인 유사성이 존재할 가능성을 제기합니다. 그럼에도 불구하고, 사람들은 인간의 뇌와 딥러닝 모델의 구조가 구조적으로 다르다고 생각하는 경향이 있습니다. 마치 의식이라는 초월적인 무언가를 상정해두고 이 것이 두개골 속에 자리잡아 모든 것을 인지하고 해석하는 듯이 말입니다. 그러나 영국의 신경과학자 아널 세

¹ 유발 하라리, *호모데우스*, (서울: 김영사, 2017)

² 유발 하라리, *호모데우스*, (서울: 김영사, 2017)

³ 오철우, "‘나’의 의지인가 ‘뇌’의 명령인가" *한겨레*, 19/10/2019, https://www.hani.co.kr/arti/science/science_general/283766.html

스가 집필한 "내가 된다는 것"에 따르면, 뇌의 인지 과정은 단순히 감각 정보의 원인을 역추론하는 딥러닝 모델처럼 작동합니다. 외부 자극을 받아들일 때마다 기억과 경험을 데이터베이스 삼아 최적의 해석을 생성하고, 실제 감각과의 오차를 지속적으로 보정하는 생물학적 베이저안 모델에 가깝다는 것입니다.⁴ 딥러닝 모델 또한 인간의 뇌의 이러한 메커니즘과 유사한 방식으로 동작합니다. 수많은 연산을 통해 가중치를 부여하고, 이를 통해 예측하며 실제 관측된 데이터와의 차이를 통해 그 오류를 줄여가는 방향으로 모델을 개선합니다. 사람들이 직관적으로 생각하는 것과는 다르게, 인간의 뇌와 딥러닝 모델은 닮았습니다. 둘 사이의 차이는 근본적으로는 구현 방식의 차이에 기인하며, 딥러닝 모델은 뇌의 논리적 구조와 유사한 방향으로 수렴하고 있다고 볼 수 있습니다. 현재의 인공지능이 지능의 다면적 측면의 일부만을 모사한 불완전한 지능이라는 비판은 타당하나, 인공지능이 본격적으로 두각을 드러낸 것이 고작 10년 정도밖에 되지 않았다는 사실을 감안하면 현재만을 가지고 앞으로의 가능성까지 단정짓는 일은 시기상조입니다. 향후 기술이 발전함에 따라 일반적인 개념의 자유의지를 가진 인공지능으로 발전할 가능성 역시 배제할 수 없습니다.

위 문단에서 언급한 바와 같이 인간의 의사결정 과정과 인공지능의 의사결정 모델 사이 구조적인 유사성이 존재하는 것은 사실입니다. 그러나 위 문단과 같은 주장은 인간과 인공지능 사이에 존재하는 근본적인 차이를 간과한 주장입니다. 인간의 의식은 단기간에 인위적으로 개발된 인공지능과는 달리 수십 억년간 거듭되어 온 진화의 산물입니다. 의식이 강한 개체가 약한 개체에 비해 사냥, 번식, 협동, 미래 예측과 같은 다양한 환경에서 지속적인 우위를 드러내어 점차 의식이 강해지는 방향으로 진화하게 된 것입니다. 반면에, 인공지능의 판단에는 이러한 진화적 맥락이 결여되어 있습니다. 인공지능이 수행하는 수많은 텐서 연산은 의식을 발현하기 위하여 필요한 주관적인 경험과 질적으로 다릅니다⁵. 마찬가지로 진화라는 맥락 속에서 의식은 결코 신체적 경험과 분리될 수 없습니다. 손을 베이면 아픈 것처럼, 신체의 수많은 감각기관에서 보내는 신호는 주관적인 경험을 형성하여 의식의 일부가 됩니다. 반면에 인공지능은 신체와 감각이 없기 때문에 위와 같은 주관적인 경험을 체험할 수 없습니다. 설령 비슷한 반응을 보였다 한들 그 반

⁴ 최원형, "[책&생각] 의식은 '살아 있다'는 느낌으로부터 온다", *한겨레*, 01/07/2022, <https://www.hani.co.kr/arti/culture/book/1049264.html>

⁵ 이경전, "(16) 인공지능은 의식을 가질 수 있을까", *주간경향*, 09/12/2024, https://m.weekly.khan.co.kr/view.html?artid=202411291550041&code=114&med_id=weekly#c2b

응은 의미론적인 재현이 아닌 통계적으로 에뮬레이팅된 반응에 불과합니다. 뇌와 인공지능 모델 사이의 구조적인 유사성을 근거로 인공지능이 의식을 가질 수 있다고 주장하는 것은 카메라가 세상을 볼 수 있다고 주장하는 것과 같습니다. 앞을 보기 위해서는 눈 뿐만 아니라 뇌도 필요하듯, 의식을 가지기 위해서는 뇌 뿐만 아니라 단어에 의미를 부여할 주관적이고 감각적인 경험이 존재가 필수불가결합니다. 그러나 현재 인공지능 모델은 그러한 경험을 할 수 없습니다. 그렇기에 구조적 유사성만으로는 인공지능이 의식을 가질 수 없으며, 그러한 주장은 일부 공통점을 침소봉대한 과도한 논리적 비약입니다.

위에서 다시 확인했듯이, 현재 인공지능의 한계는 명확합니다. 현대의 인공지능은 근본적으로 특정한 목적에 종속되어 있으며, 일부 문제에서 드러나는 부분적 자율성 역시 손실 함수의 최소화를 위한 수학적 최적화의 산물에 불과합니다. 반면에 인간의 자유의지는 수십 억년간 거듭된 진화의 산물입니다. 진화의 과정에서 발생한 자유의지는 결코 생존본능으로부터 자유로울 수 없으며, 신체와 분리된 수학적 모델만으로는 흉내낼 수는 있을지 언정 결코 같아질 수 없습니다. 그럼에도 불구하고 인공지능의 자율성을 완전히 부정하는 것만이 능사는 아닙니다. 앞으로 기술이 발전하면서 짧으면 수년, 길면 수십년 이내로 자유의지를 가진 인공지능까지는 아닐지라도 사람이 그 행동을 온전히 예견, 통제할 수 없는 강인공지능의 등장할 가능성이 상당히 높게 점쳐지고 있습니다. 이러한 인간이 통제할 수 없는 강인공지능이 야기할 수 있는 범죄 악용 가능성과 그 외의 윤리적인 딜레마는 산더미같이 쌓여 있습니다. 그러나 이러한 가능성을 부정하고 인공지능으로 인해 발생한 문제를 사용자나 개발자에게 온전히 귀속시키려 하는 것은 상당한 사회적 혼란을 야기할 것입니다.⁶ 인공지능 발달로 발생할 위와 같은 문제를 가장 효과적으로 해결할 수 있는 방법은 인공지능에도 법인격과 같은 법적 지위를 부여하여 법적인 권리와 책임을 부여하는 것입니다. 인간의 능력으로는 통제할 수도, 예견할 수도 없었던 인공지능이 일으킨 문제의 책임으로부터 개발자와 사용자를 분리하는 것은 인공지능의 발전을 촉진시키고, 인간 활동의 저변을 넓히는데 기여할 것입니다. 법인이 자아를 가지지 않음에도 불구하고 사회적 필요에 의해 법인격 개념을 부여받았듯이, 인공지능에게도 법적인 책임과 권리를 부여할 수 있는 제도적 장치가 필요합니다. 그러나 이와 같은 변화를 위해서는 단순한 법률 개정하거나 규제를 강화하는 것만으로는 충분하지 않습니다. 일부 악의적인 개인이나 집단이 근본적으로 결함이 있는 인공지능을 만들어 사람들을 기망하고도 법망을 빠져나가는 사태를 방지해서는 안됩니다. 이러한 과제를 해결하기 위해

⁶ 김성호, "인공지능에 대한 법인격 부여 필요성", 법학논총, 37권 3호, p145

서는 인공지능의 행위로 발생하는 결과에 대한 책임 소재, 의도와 결과 사이의 인과, 그리고 인공지능이 스스로 학습하는 과정에서 생길 수 있는 예측 불가능성까지 모두 투명하게 고려하고 살펴볼 수 있어야 합니다. 인공지능의 설계와 학습 과정에서 발생하는 예측 불가능성을 해결하기 위해서는 모델의 의사결정 프로세스를 투명하게 하는 기술적 장치가 필수적으로 마련되어야 합니다. 개발자조차 정확한 메커니즘을 모르고 동작하는 현재의 블랙박스 구조에서 벗어나 이러한 기술적 장치를 구축하는 것은 인공지능에 대한 사회적인 신뢰를 만들고 보다 다양한 분야에 인공지능이 응용되는 데에도 결정적인 역할을 할 것입니다. 이처럼, 인공지능의 법적 지위 논의는 결코 현실과는 동떨어진 추상적 담론이 아니라 코 앞까지 다가온 현실의 문제입니다. 기술의 발전 속도를 제도가 따라가지 못할 때 발생하는 혼란은 개인의 삶부터 국가 경제 시스템까지 광범위한 영향을 미칩니다. 이러한 혼란을 줄이면서도 인공지능이란 기술의 잠재력을 활용하기 위해서는 유연함과 엄격함의 조화가 필요합니다. 한치 앞도 내다 볼 수 없는 격변의 시대에서 완벽한 규제를 추구하는 것은 아무 것도 하지 않겠다는 것과 같습니다. 우리가 준비해야 할 것은 완벽한 해결책이 아니라 유연한 해결책입니다. 더 이상 인공지능과 인간의 공존은 선택이 아니라 필수입니다. 앞으로 인공지능이 가져올 변화의 세계에서 우리는 인공지능 기술의 발전과 무고한 피해자의 보호라는 두 가지 목표 중 어느 하나도 소홀히 해서는 안 됩니다. 인공지능의 혁신은 사회와 경제 전반에 걸쳐 새로운 기회를 제공하고, 우리의 삶을 더욱 풍요롭고 효율적으로 만들어줄 잠재력을 가지고 있습니다. 하지만 동시에, 기술의 오남용이나 예기치 못한 결함으로 인해 발생할 수 있는 피해자들을 외면한다면, 인공지능이 가져올 미래는 결코 긍정적일 수 없습니다. 따라서 우리는 기술 발전의 속도를 따라잡는 동시에, 그 과정에서 발생할 수 있는 윤리적, 법적 문제에 대한 충분한 대비책을 마련해야 합니다. 이는 단순히 규제를 강화하거나 기술을 억제하는 것만으로는 이룰 수 없습니다. 오히려 사회 전체가 유연하게 대응할 수 있는 체계를 마련하고, 다양한 이해관계자들이 지속적으로 소통하며 합의점을 찾아가는 과정이 필요합니다. 예측 불가능한 변화 속에서도 피해를 최소화하고, 동시에 혁신의 동력을 잃지 않도록 균형을 맞추는 것이야말로 우리가 나아가야 할 방향입니다.